训练端
模型训练与权重产出

模型格式转换
围绕特别板端可执行模型

板端运行与后处理
板端推理、解码、 NMS 与安全输出

1. 训练权重 PyTorch / YOLO

YOLO 网络结构（简化）

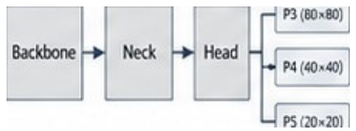

权重参数（部分张量示意）

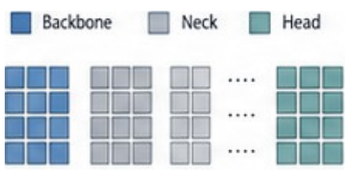

检测类（双目标）

输出维度： [batch, anchors, (5 + num_classes)]

类别语义顺序： person(0) / ebike(1)

输出语义 尺寸 / 通道 / 归一化

2. ONNX 导出 中间表示

ONNX graph

输入张量 [1, 3, H, W]
↓
Conv [1, C1, H/2, W/2]
↓
SiLU [1, C1, H/2, W/2]
↓
Detect Head [1, A×(5+2), Hs, Ws]
↓
输出张量 boxes / score / class [1, N, (5+2)]

注：
N = 预测框个数， A=anchors

图结构及算子通用名称

3. ATC 编译 算子适配

ONNX 原始 (FP32)

Input
↓
Conv
↓
BN
↓
SiLU
↓
MatMul
↓
...
↓
Detect Head
↓
Output

operator lowering / fusion

Ascend / NPU kernel （适配后）

AIPP （预处理）
↓
Conv + BN （融合）
↓
SiLU （融合）
↓
MatMul （映射优化）
↓
...
↓
Detect Head （自定义算子）

主要优化：算子融合 / 格式转换 / 内存复用 / 调度适配

设备可执行语义 / 算子适配 / 尺度信息

4. OM 模型 离线模型

OM 模型包结构 （.om）

模型包及运行配置 / 输入请求

5. NPU 推理 模型执行

NPU 执行结构（板端）

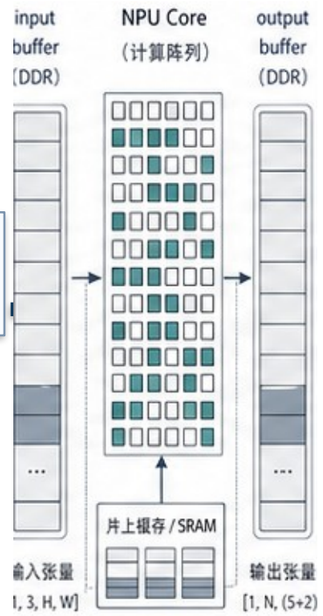

执行 OM 模型： 调度算子 / 并行计算

输出结果张量 / 送入 NMS

6. 解码与 NMS 安全输出

模型输出张量（原始） [1, N, (5+2)]

bbox decode （坐标还原）

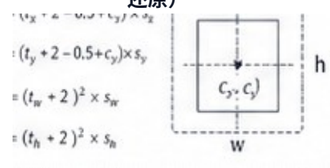

类别分数（ person / ebike ）

sigmoid / softmax

NMS 后结果（保留框）

序号	类别	x1	y1	y2	y2	score	class
1	person	78	52	168	362	0.92	0
2	ebike	196	74	276	336	0.87	1
...							

类别语义： person / ebike 顺序一致（训练 → 导出 → 编译 → OM → 推理 → 后处理）

模型格式转换（离线）

板端运行与后处理（在线）