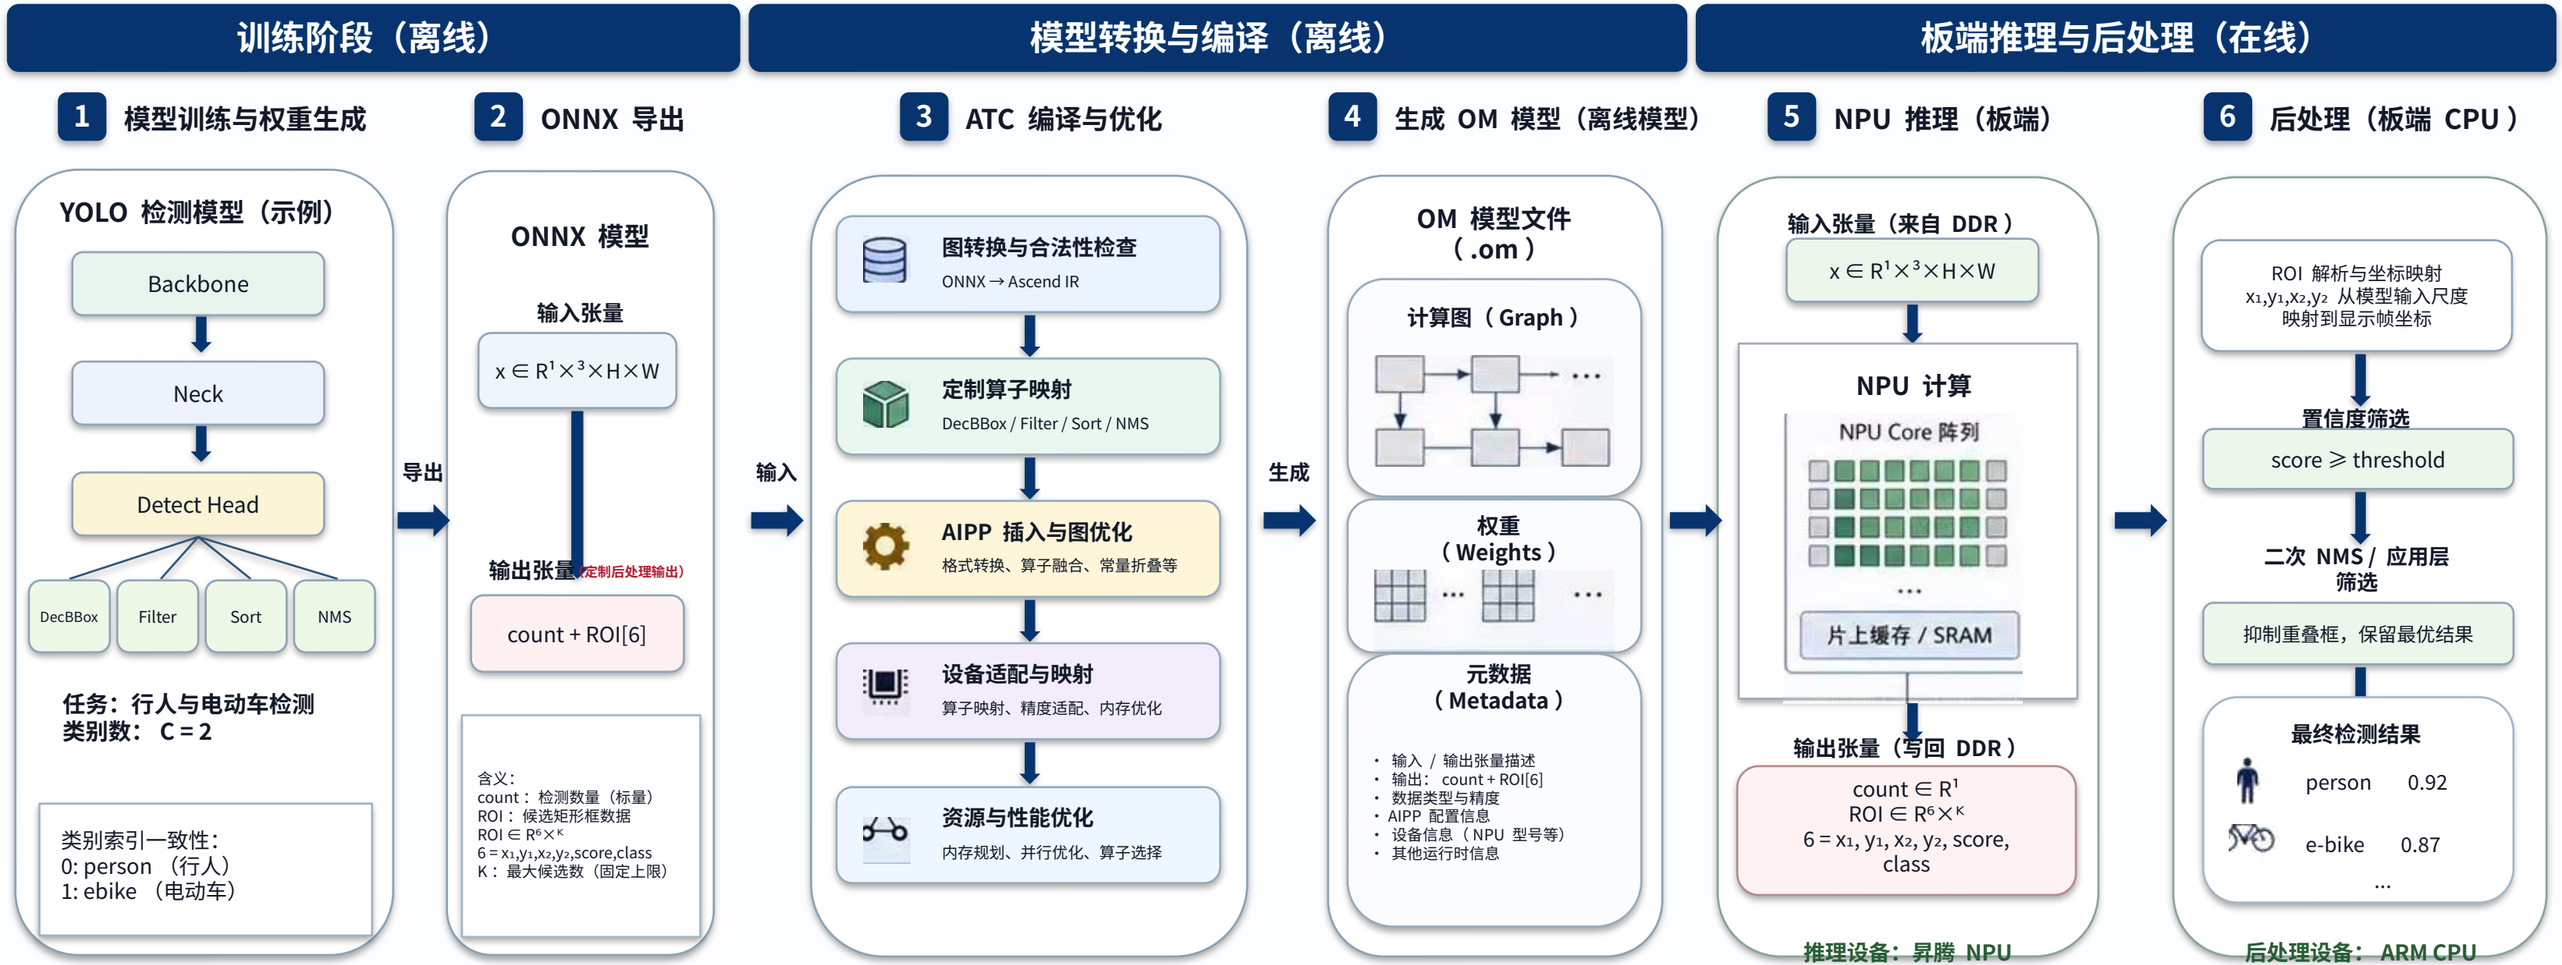
训练阶段（离线）
模型转换与编译（离线）
板端推理与后处理（在线）
1 模型训练与权重生成
2 ONNX 导出
3 ATC 编译与优化
4 生成 OM 模型（离线模型）
5 NPU 推理（板端）
6 后处理（板端 CPU）
YOLO 检测模型（示例）
Backbone
Neck
Detect Head
DecBBox
Filter
Sort
NMS
任务：行人与电动车检测
类别数： C = 2
类别索引一致性：
0: person （行人）
1: ebike （电动车）
导出
ONNX 模型
输入张量
x ∈ R¹×³×H×W
输出张量（定制后处理输出）
count + ROI[6]
含义：
count： 检测数量（标量）
ROI： 候选矩形框数据
ROI ∈ R⁶×ᴷ
6 = x₁,y₁,x₂,y₂,score,class
K： 最大候选数（固定上限）
输入
图转换与合法性检查
ONNX → Ascend IR
定制算子映射
DecBBox / Filter / Sort / NMS
AIPP 插入与图优化
格式转换、算子融合、常量折叠等
设备适配与映射
算子映射、精度适配、内存优化
资源与性能优化
内存规划、并行优化、算子选择
生成
OM 模型文件
（.om）
计算图（Graph）
权重
（Weights）
元数据
（Metadata）
• 输入 / 输出张量描述
• 输出： count + ROI[6]
• 数据类型与精度
• AIPP 配置信息
• 设备信息（NPU 型号等）
• 其他运行时信息
输入张量（来自 DDR）
x ∈ R¹×³×H×W
NPU 计算
NPU Core 阵列
片上缓存 / SRAM
输出张量（写回 DDR）
count ∈ R¹
ROI ∈ R⁶×ᴷ
6 = x₁, y₁, x₂, y₂, score, class
推理设备：昇腾 NPU
ROI 解析与坐标映射
x₁,y₁,x₂,y₂ 从模型输入尺度
映射到显示帧坐标
置信度筛选
score ⩾ threshold
二次 NMS / 应用层
筛选
抑制重叠框，保留最优结果
最终检测结果
person 0.92
e-bike 0.87
...
后处理设备： ARM CPU