華南理工大學

South China University of Technology

本科毕业设计（论文）

基于深度学习的电梯边缘 AI 安全视觉关键技术研究与实现

学　　院	计算机科学与工程学院
专　　业	计算机科学与技术全英创新班
学生姓名	叶伟键
学生学号	202230430217
指导教师	钟竞辉
提交日期	2026 年 4 月 28 日

华南理工大学

学位论文原创性声明

本人郑重声明：所呈交的论文是本人在导师的指导下独立进行研究所取得的研究成果。除了文中特别加以标注引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写的成果作品。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律后果由本人承担。

作者签名：

日期：2026 年 4 月 28 日

学位论文版权使用授权书

本学位论文作者完全了解学校有关保留、使用学位论文的规定，即：学校有权保存并向国家有关部门或机构送交论文的复印件和电子版，允许学位论文被查阅；学校可以公布学位论文的全部或部分内容，可以允许采用影印、缩印或其它复制手段保存、汇编学位论文。本人电子文档的内容和纸质论文的内容相一致。

作者签名：

日期：2026 年 4 月 28 日

指导教师签名：　　日期：2026 年 4 月 28 日

作者联系电话：　　电子邮箱:

摘　要

电梯轿厢是典型的封闭式高频公共微空间，具有反光强、遮挡多、视角近、目标尺度变化快和事件响应时延要求高等特点。针对电动车入梯风险治理中离线检测精度与边缘部署表现可能不一致的问题，本文以电梯轿厢场景中的行人与电动车双目标检测为研究对象，围绕 YOLO 双目标检测、海思/昇腾类边缘开发板兼容迁移和部署一致性评价开展研究。本文的核心思路是：电梯边缘安全视觉的可用性不仅取决于模型能否识别目标，还取决于任务建模是否贴合风险、迁移接口是否保持语义一致、实验指标是否能够解释板端真实运行口径。

首先，本文分析电梯轿厢的空间结构、成像特点和安全响应需求，明确行人与电动车双目标检测任务边界。其次，结合 YOLO 检测器的 Backbone、Neck、Head 和后处理流程，将自训练权重到 ONNX 中间表示、OM 离线模型和板端推理的过程抽象为输入、类别、输出、后处理和运行五类迁移接口契约。最后，针对模型迁移到边缘设备后可能出现的类别语义、边框解释、阈值行为和运行时口径变化，构建部署一致性评价框架，并以完整验证集、分类别指标、阈值后验重算、分段计时和代表性视频片段作为证据来源。

实验结果表明，在 720 张图像构成的验证集上，边缘设备端总体 precision 为 0.901，recall 为 0.923，F1 为 0.912，mAP@0.5 为 0.910；其中行人类别 mAP@0.5 为 0.869，电动车类别 mAP@0.5 为 0.952。阈值敏感性后验重算显示，在 0.20–0.35 置信度阈值范围内，总体 F1 保持在 0.915–0.922 区间，电动车召回率保持在 0.956 以上。板端 batch 图像验证链路端到端平均单图处理耗时约为 1120 ms；进一步的分段计时表明，50 张图像 batch 复查中模型执行阶段均值约为 8.2 ms，代表性连续视频处理中模型执行阶段均值约为 8.4 ms。上述结果说明，本文方法在当前验证集与代表性片段范围内表现出较稳定的双目标检测能力，并提供可复查的部署一致性证据。

关键词：　电梯安全视觉；边缘智能；目标检测；部署一致性；电动车入梯检测

Abstract

Elevator cabins are closed, high-frequency public micro-spaces characterized by strong reflections, frequent occlusions, close viewpoints, rapid scale variation, and strict latency requirements for safety response. To address the potential gap between offline detection accuracy and edge-device behavior in e-bike-in-elevator risk governance, this thesis studies pedestrian and e-bike detection in elevator cabins, focusing on YOLO-based dual-target detection, compatible migration to HiSilicon/Ascend-like edge boards, and deployment consistency evaluation. The central idea is that the usability of elevator edge safety vision depends not only on whether a model detects targets, but also on whether the task formulation matches the safety risk, whether the migration interface preserves semantics, and whether the evaluation metrics explain the actual board-side runtime behavior.

First, this thesis analyzes the spatial structure, imaging characteristics, and safety requirements of elevator cabins, and defines the dual-target detection task for pedestrians and e-bikes. Second, based on the Backbone, Neck, Head, and post-processing pipeline of YOLO detectors, the migration from self-trained weights to ONNX, OM offline models, and board-side inference is formulated as five interface contracts: input, category, output, post-processing, and runtime contracts. Finally, to analyze behavior changes after edge deployment, a deployment consistency framework covering category semantics, bounding-box interpretation, threshold behavior, and runtime measurements is constructed, using full validation, per-class metrics, posterior threshold recomputation, segmented timing, and representative video snippets as evidence sources.

Experimental results show that on a 720-image validation set evaluated on the edge device, the system achieves an overall precision of 0.901, recall of 0.923, F1 of 0.912, and mAP@0.5 of 0.910. The pedestrian class reaches 0.869 mAP@0.5, while the e-bike class reaches 0.952 mAP@0.5. A posterior threshold-sensitivity recomputation shows that the overall F1 remains within 0.915–0.922 under confidence thresholds from 0.20 to 0.35, and the e-bike recall remains above 0.956. The end-to-end average processing time of the board-side batch image validation path is approximately 1120 ms per image; additional segmented timing shows that the mean model-execution stage is about 8.2 ms in a 50-image batch check and about 8.4 ms in a representative continuous-video run. These results indicate stable dual-target detection within the current validation set and representative snippets, while providing reproducible evidence for deployment-consistency evaluation in elevator edge-vision scenarios.

Keywords: Elevator safety vision; Edge intelligence; Object detection; Deployment consistency; E-bike-in-elevator detection

目　录

摘　要 ..... **I**

Abstract ..... **II**

目　录 ..... **IV**

插图目录 ..... **VII**

表格目录 ..... **VIII**

第一章　绪论 **1**

1.1　研究背景 1

1.2　场景约束与问题挑战 1

1.3　国内外研究现状 2

1.3.1　边缘智能与轻量部署方向 2

1.3.2　轻量目标检测与实时视觉方向 3

1.3.3　困难样本分析与数据增强方向 3

1.3.4　相关场景研究与当前不足 4

1.4　问题定义与核心思路 4

1.5　研究目标与主要内容 5

1.6　研究难点分析 5

1.7　本文的主要贡献 6

1.8　研究内容组织逻辑 6

1.9　论文结构安排 7

第二章　技术基础与相关工作 **8**

2.1　目标检测基础 8

2.2　YOLO 系列检测器与 YOLOv8 特点 10

2.3　海思/昇腾类边缘 AI 部署基础 12

2.4　后处理、NMS 与部署参数敏感性 13

2.5　相邻视觉任务与本文边界 14

2.6　部署一致性问题 14

2.7 相关工作小结 15

第三章 YOLO 双目标检测模型的边缘兼容迁移方法 16

3.1 总体技术路线 16

3.2 迁移接口契约 17

3.3 关键一致性环节 18

3.3.1 输入预处理对齐 18

3.3.2 类别语义对齐 18

3.3.3 输出张量语义对齐 18

3.3.4 后处理一致性 18

3.3.5 运行时可靠性 19

3.4 一致性评价方法 19

3.5 本章小结 20

第四章 数据集、场景复杂性与评测协议 21

4.1 任务与数据组织 21

4.2 场景复杂性因素 21

4.3 评测指标设计 22

4.4 实验协议 22

4.5 场景复杂性与部署误差的关系 22

4.6 数据集划分与可复查性要求 23

4.7 跨阶段一致性实验设计 23

4.8 实验结果呈现原则 23

4.9 本章小结 24

第五章 实验结果与分析 25

5.1 实验设置与评价范围 25

5.2 RQ1：板端完整验证集是否保持检测能力 26

5.3 RQ2：分类别输出是否符合任务语义 26

5.4 RQ3：阈值变化是否影响安全输出 27

5.5 RQ4：NMS 参数如何影响候选框保留 28

5.6 RQ5：后处理策略消融如何界定部署模块作用 29

5.7 RQ6：代表性视频片段如何补充稳定性观察 29

5.8 RQ7：分段计时如何解释运行时口径 30

5.9 部署一致性综合分析 31
5.10 场景风险与误差解释 31
5.11 结果讨论与局限 32
5.12 本章小结 32

结论与展望 33

参考文献 35

致谢 40

附录 A 补充复查表格 41
A.1 困难样本复查字段 41
A.2 部署一致性复查字段 41

插图目录

1-1 本文采用的电梯边缘安全视觉研究流程 2

2-1 YOLO 双目标检测流程 10
2-2 海思/昇腾类开发板上的 YOLO 部署链路 12

3-1 YOLO 双目标检测模型的边缘兼容迁移流程 16

5-1 边缘设备端总体指标与分类别指标 27
5-2 置信度阈值敏感性曲线 28
5-3 板端分段计时结果对比（对数坐标） 31

表格目录

2-1 电梯场景检测与通用开放场景检测的差异 9

5-1 边缘设备端总体检测结果 26
5-2 边缘设备端分类别检测结果 26
5-3 置信度阈值敏感性后验重算结果 27
5-4 板端分段计时结果 30

A-1 困难样本复查字段 41
A-2 部署一致性复查字段 41

第一章 绪论

1.1 研究背景

电梯轿厢是城市建筑中最典型的高频公共微空间之一，其空间尺度小、人员流动快、目标遮挡强、光照变化复杂，并且往往伴随镜面反光、金属门框高亮和近距离透视畸变等问题。对于通用视觉模型而言，这类成像环境与开阔道路、固定走廊或通用开放数据集存在明显差异。与此同时，电梯属于安全敏感场景，系统不仅需要“看得见”，更要“看得准、报得稳、跑得动”。一旦模型在真实部署中出现持续漏检、误检或跨端行为漂移，就可能直接影响风险治理效果。

在现实应用层面，电动车入梯是当前电梯安全治理中的高关注事件之一。与普通静态物体检测任务不同，电动车入梯往往伴随人与车同时出现、局部遮挡、仅露出车头或车把、人员身体压住车身、门口区域边框干扰等复杂情况。这意味着系统不仅要识别 *ebike*，还必须同时识别 *person*，并利用二者的相对关系理解事件上下文。因此，围绕人和电动车的双目标检测建立统一的边缘视觉方案，是比单类检测更贴近真实部署需求的技术路径。

随着边缘计算理论和端侧智能硬件的发展，在数据源附近完成推理与初步决策已经成为安全视觉系统的重要趋势 [1]。将模型部署在边缘侧有三个直接优势：第一，原始视频不必持续上传到云端，可以降低带宽与隐私压力；第二，事件响应链路更短，更适合时延敏感的电梯预警；第三，设备运行与模型行为可以在本地形成更加稳定的评价记录。然而，边缘部署并非简单的模型格式转换，而是需要同时解决模型轻量化、量化与编译、后处理阈值稳定性、跨格式一致性等问题。

在此背景下，本文以电梯轿厢行人与电动车双目标检测为中心，研究基于 YOLO 的自训练检测模型如何兼容迁移到海思/昇腾类边缘开发板，并在设备端保持类别、边框、阈值和运行时行为的一致性。

1.2 场景约束与问题挑战

与普通目标检测相比，电梯轿厢边缘安全视觉存在更强的约束耦合。本文将这些约束概括为以下五类。

1) **视角与尺度约束。**电梯摄像机通常安装在轿厢顶部或角落，拍摄距离近、视角固定但透视变化明显。人在近景和门口区域会出现边框被截断、下半身出框或头肩放大的现象，电动车则常以局部结构出现。

2) **反光与遮挡约束**。金属门板、镜面装饰和玻璃表面会产生高亮或虚像，而人与电动车共同出现时又会互相遮挡，导致检测器在类别判断和边框定位上更加不稳定。
3) **边缘部署约束**。边缘设备通常受限于算力、功耗、存储和算子支持能力，这决定了模型不能无限增大，训练端结构也不一定能无损迁移到部署端。
4) **运行时稳定性约束**。安全场景更关心连续视频中的稳定表现，而不是孤立图像上的最好指标。即使某一帧检测正确，只要系统在连续数秒内频繁闪烁或类别来回跳变，也会影响真实使用。
5) **结论可复查约束**。论文中的实验结论不能只停留在经验判断，还需要能够回溯到验证集、指标摘要和设备端运行结果，形成从模型到系统的可复查评价依据。

图 1-1 给出了本文采用的整体研究流程。该流程的关键不在于追求抽象的最佳模型，而在于把电梯场景中的难例分析、模型迁移与边缘一致性诊断统一到同一套评价框架中。

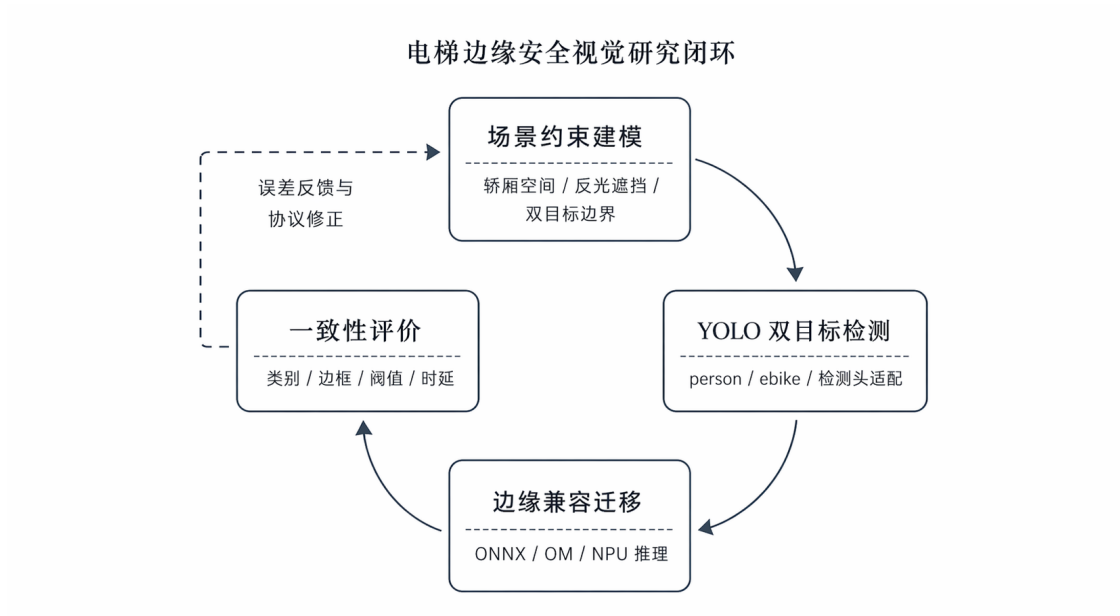

图 1-1 本文采用的电梯边缘安全视觉研究流程

1.3 国内外研究现状

1.3.1 边缘智能与轻量部署方向

边缘计算研究已经系统性指出，在靠近数据源的位置完成计算与服务提供，是降低时延、缓解带宽压力和提升隐私保护能力的有效方式 [1]。这一思想为电梯场景提供了天然契合点：视频流敏感且实时性强，如果完全依赖云端处理，不仅会产生隐私问题，

也会带来额外的网络波动风险。为了让视觉模型真正适应边缘设备，研究者提出了量化、剪枝、蒸馏等模型压缩与加速方法。Jacob 等提出的整数推理友好量化框架表明，神经网络可以在低位宽下保持较好的性能 [2]；Han 等提出的 Deep Compression 则从剪枝、量化和编码三方面给出了经典压缩思路 [3]；知识蒸馏方法进一步提供了从大模型向轻量模型迁移判别能力的通用工具 [4]。

然而，边缘部署研究在实际落地时还面临一个常被忽视的问题，即兼容迁移与行为一致性。训练端的浮点模型在导出、量化和编译后，可能在边框位置、类别分数排序和阈值敏感性上出现漂移。对于普通离线基准，这种问题可能只表现为小幅指标变化；但在安全场景中，它可能被放大为连续视频中的误报、闪烁和漏检。因此，部署研究不能只停留在编译成功，还应关注跨格式链路的一致性分析 [5-6]。

1.3.2 轻量目标检测与实时视觉方向

实时目标检测是当前工业视觉中最成熟的方向之一。YOLO 系列以端到端、结构简洁和工程可用性强著称，在大量真实场景中获得了广泛应用 [7]。为了适配不同计算预算，研究者进一步提出了可伸缩的检测网络设计，例如 EfficientDet 通过跨尺度特征融合和复合缩放策略，在精度与计算量之间取得了较好的平衡 [8]；MobileNetV3 和 EfficientNet 则分别从移动端神经架构搜索和统一缩放规律角度，为轻量骨干网络设计提供了重要参考 [9-10]。此外，EdgeYOLO 等工作进一步把边缘实时检测作为设计目标，强调算子友好性、端侧吞吐和推理效率 [11]。

电梯场景中的双目标检测与通用检测任务相比更强调轻量性和稳定性。一方面，模型需要识别行人与电动车两个类别，类别数较少，理论上适合轻量模型；另一方面，轿厢内遮挡、反光和近距离尺度变化又会放大轻量模型的表达不足。因此，本文采用轻量 YOLO 模型作为实现基础，并把可部署性和一致性评价纳入方法设计，而不把模型规模对比作为当前已完成的主体实验。

1.3.3 困难样本分析与数据增强方向

当目标检测任务受到长尾样本和困难样本主导时，仅靠扩大数据量并不能稳定提升系统表现。OHEM 等在线难例挖掘方法强调，让模型更多关注当前最难的样本，可以提升训练效率并改善关键失败模式 [12]。在目标检测场景中，定向数据增强也是提升泛化能力的重要手段。Scale-Aware Automatic Augmentation 等研究证明，针对目标尺度、位置和场景结构设计增强策略，往往比无差别增强更有效 [13]。

电梯轿厢中的困难样本具有明显场景规律：反光区域集中在门板和镜面结构，遮挡

多发生在人车重叠区域，电动车局部可见常出现在门口或边缘位置。因此，本文将困难样本分类作为场景风险建模和误差解释工具，用于说明指标变化与实际轿厢结构之间的关系。针对困难样本的重加权训练、定向增强和模型尺度对比仍属于后续可扩展实验，本文不将其作为已经完成的算法改进结论。

1.3.4 相关场景研究与当前不足

与通用监控或道路交通相比，直接面向电梯视觉的公开研究数量并不多。已有工作多聚焦于人数统计、乘客计数或局部行为识别，例如基于 MobileNet-SSD 的电梯人数统计系统研究表明，在电梯场景中采用边缘侧轻量模型是具备现实可行性的 [14]。另一些研究则尝试将轻量模型用于电梯跌倒检测，说明电梯作为独立应用场景具有实际研究价值。

不过，现有研究通常只覆盖单一任务或单一部署环节，较少同时讨论电梯轿厢中的行人与电动车双目标检测、场景风险解释以及训练端到边缘端的一致性问题。本文正是在这一不足上展开：以双目标检测为主线，以场景风险建模和部署一致性评价为两条支撑线，形成面向电梯安全视觉的研究框架。

1.4 问题定义与核心思路

从系统角度看，电梯边缘安全视觉并不是单一的图像分类或离线检测任务，而是一个跨越数据、模型、编译工具和边缘设备的完整链路问题。若只在服务器端验证模型精度，无法说明模型在开发板上是否仍然保持相同输出；若只说明模型可以在板端运行，又无法解释输出结果是否与训练端语义一致。因此，本文将研究问题定义为：如何使基于 YOLO 的电梯双目标检测模型在海思/昇腾类边缘开发板上完成兼容迁移，并通过可量化指标评价部署后行为。

围绕这一问题，本文采用“问题链—技术缺口—核心处理方式”的组织思路。首先，电梯安全视觉任务需要刻画人车共现、遮挡反光和局部可见等轿厢因素，因此本文将电动车入梯治理抽象为 $person + ebike$ 双目标检测问题。其次，模型边缘迁移不能只被视为环境配置，输入、类别、输出和后处理约束都需要显式检查，因此本文将 PyTorch、ONNX、OM 和板端后处理抽象为迁移接口契约。最后，实验结果解释不能只依赖离线 mAP 或单一平均耗时，而需要结合完整验证集、分类别指标、阈值重算、分段计时和视频片段观察来说明部署后的模型行为。

本文的核心思路是：对于电梯轿厢这类封闭式安全场景，模型的应用价值不只取决于离线检测精度，还取决于任务定义是否贴合风险、迁移接口是否保持语义一致、实验

指标是否能够解释板端真实运行口径。换言之，本文把 YOLO 双目标检测、边缘兼容迁移和部署一致性评价作为同一条研究主线，而不是三个彼此割裂的工程步骤。

该问题具有三方面研究动机。第一，电梯安全视觉对漏检和误检都敏感，模型迁移过程中的小幅数值变化可能被放大为报警行为差异。第二，YOLO 检测器虽然部署友好，但其输出张量、类别顺序和后处理参数必须被正确解释，否则板端结果会偏离训练端预期。第三，海思/昇腾类边缘平台采用专用 NPU 和离线模型格式，部署链路中存在 ONNX 导出、ATC 编译、OM 模型执行和应用层后处理等多个可能引入差异的环节。

基于上述动机，本文将“检测精度”和“部署一致性”同时作为评价目标。检测精度回答模型能否识别行人与电动车，部署一致性回答模型迁移到边缘设备后是否仍以相同语义、稳定阈值和清晰运行口径输出结果。二者结合，才能较完整地评价电梯边缘安全视觉系统的可用性。

1.5 研究目标与主要内容

本文的研究目标是：面向电梯轿厢行人与电动车双目标检测任务，构建一套基于 YOLO 的检测模型边缘兼容迁移方法，并通过统一实验协议验证模型在海思/昇腾类开发板上的检测精度、阈值行为和运行时口径。本文并不把难例分类本身作为独立算法创新，而是将其作为解释检测误差和部署稳定性的场景约束。围绕这一目标，本文主要开展以下工作。

1) 建立电梯轿厢双目标检测任务定义，明确行人与电动车两个核心类别，使研究对象稳定服务于电动车入梯风险识别。
2) 总结电梯场景中的典型困难样本，形成用于误差解释和实验分组的场景风险分类体系。
3) 分析 YOLO 检测器在双目标任务中的结构适配方式，明确输入尺寸、类别顺序、检测头输出和 NMS 后处理对部署结果的影响。
4) 构建从自训练权重、ONNX、OM 到边缘设备执行的兼容迁移链路，重点关注类别一致、边框解释一致、阈值稳定和运行状态可追溯。
5) 在统一验证集、代表性片段和分段计时实验上进行分析，给出总体指标、分类别指标、阈值敏感性和边缘设备运行表现。

1.6 研究难点分析

本文研究难点主要体现在三个层面。第一是任务层面的难点。电梯轿厢内行人与电动车经常同时出现，且存在遮挡、反光、局部可见和尺度变化等问题，模型需要在较小

类别集合中保持稳定检测，而不是简单识别静态物体。

第二是模型层面的难点。YOLO 检测器具有较好的实时性，但其检测头输出、坐标解码、置信度筛选和 NMS 后处理共同决定最终结果。训练端脚本通常自动完成这些步骤，而板端应用程序需要显式实现或调用相应逻辑。只要其中一个环节解释不一致，最终输出就可能变化。

第三是部署层面的难点。海思/昇腾类边缘开发板采用专用编译和运行时体系，模型需要从训练权重转换为可执行离线模型。转换过程中的算子适配、预处理配置、数据类型变化和输出读取方式，都会影响设备端行为。因此，本文需要把部署链路纳入论文方法，而不是把它视为实验环境说明。

1.7 本文的主要贡献

本文的主要贡献可以概括为以下三点。

1) **面向电梯轿厢的双目标检测任务建模。**本文将电动车入梯治理抽象为行人与电动车双目标检测问题，并用场景风险分类解释遮挡、反光和局部可见等因素对检测输出的影响。
2) **自训练 YOLO 模型的边缘兼容迁移方法。**本文围绕输入预处理、类别顺序、输出张量、后处理参数和运行时约束建立迁移接口契约，使训练权重、ONNX 中间表示、OM 离线模型和板端应用之间的关键约束能够被逐项检查。
3) **面向安全视觉的部署一致性评价。**本文不只报告检测精度，还从类别语义、边框解释、阈值行为和运行时可靠四个角度分析模型迁移后的板端行为，为电梯边缘视觉系统提供可复查的评价方式。

三项贡献分别对应后续章节的不同证据落点。第一项任务建模主要由第一章和第四章支撑，证据来自场景约束和验证集任务定义；第二项迁移接口契约主要在第三章展开，覆盖输入、类别、输出、后处理和运行五类约束；第三项部署一致性评价由第四章协议和第五章结果共同支撑，证据来自板端完整验证、分类别统计、阈值敏感性、NMS 敏感性、后处理消融、分段计时和视频片段分析。困难样本重加权、定向数据增强或模型尺度对比等内容尚未形成完整实测结果，本文将其放在后续可扩展方向中讨论。

1.8 研究内容组织逻辑

本文将研究重点放在“模型检测能力”和“边缘部署行为”两个层面。前者说明 YOLO 模型能否在验证集上识别行人与电动车，后者说明模型经过中间表示和离线模型格式进入边缘开发板后，能否继续保持可解释、可复查的输出。

基于这一思路，第二章介绍 YOLO 和海思/昇腾边缘部署基础，第三章集中给出兼容迁移方法，第四章定义数据、场景风险和评价协议，第五章基于已有验证结果分析设备端表现。这样的结构使模型训练、格式转换、设备端运行和实验评价形成连续链路。

1.9 论文结构安排

本文正文共分为五章。第一章介绍研究背景、场景挑战、研究目标和论文结构。第二章回顾目标检测、YOLO 方法、评价指标和海思/昇腾类边缘部署基础。第三章提出 YOLO 双目标检测模型的边缘兼容迁移方法。第四章给出数据组织、场景风险和评测协议。第五章给出实验结果与分析，最后在结论部分总结全文工作并讨论扩展方向。

第二章 技术基础与相关工作

本章围绕后续方法章所需的基础知识展开。由于本文的核心问题不是单纯训练一个检测模型，而是使 YOLO 双目标检测模型在海思/昇腾类边缘开发板上保持可解释、可复查的部署行为，因此本章从目标检测、YOLOv8、边缘 AI 部署和部署一致性四个方面建立技术背景。

2.1 目标检测基础

目标检测需要同时回答“目标在哪里”和“目标属于哪一类”两个问题。与图像分类只输出整幅图像类别不同，目标检测需要输出一组边界框、类别标签和置信度分数。对于电梯轿厢场景，本文只关注 *person* 与 *ebike* 两类目标，但检测任务并未因此变得简单。狭小空间中的遮挡、反光和近距离透视会使同一目标在不同帧中呈现不同尺度和形态，进而影响边框回归和类别置信度。

从深度学习目标检测的发展看，早期方法通常采用“候选区域生成 + 分类回归”的两阶段框架。R-CNN 通过卷积特征和候选区域分类显著提升了检测精度 [15]，Fast R-CNN 将特征共享和端到端训练进一步结合 [16]，Faster R-CNN 则通过区域建议网络减少外部候选框依赖 [17]。这一路线的优点是定位和分类较稳，但推理链路相对复杂，部署到资源受限的边缘设备时需要更多算子和内存支持。相比之下，SSD 将多尺度默认框和单阶段预测结合起来 [18]，YOLO 则把检测问题统一为端到端回归问题 [19]，为实时视觉和边缘部署提供了更直接的工程路径。

评价目标检测模型时，常用指标包括 precision、recall、F1、IoU 和 mAP@0.5。precision 表示预测为目标的结果中有多少是真实目标，recall 表示真实目标中有多少被成功检测，F1 则综合二者。当预测框与真实框的交并比达到阈值且类别一致时，该预测通常被视为正确检测。本文采用 mAP@0.5 评价图像级检测能力，并在安全视觉分析中同时关注分类别召回率，因为电动车漏检比普通背景误检更直接影响预警效果。

mAP@0.5 适合概括一批图像上的平均检测能力，但它不能单独回答所有部署问题。首先，mAP 是离线标注集上的统计量，无法说明板端程序是否正确解释了类别顺序和输出张量。其次，平均指标可能掩盖分类别差异，例如 *ebike* 与 *person* 在遮挡、尺度和安全含义上并不相同。最后，mAP 本身不包含运行成功率、耗时口径和后处理阈值变化等信息。因此，本文在第五章同时报告总体指标、分类别指标、阈值后验重算和分段计时，使检测性能与部署行为能够相互印证。

设某一类别的真正例、假正例和假负例分别为 TP、FP 和 FN，则 precision、recall

与 F1 可以写为

$$P = \frac{TP}{TP + FP}, \quad R = \frac{TP}{TP + FN}, \quad F1 = \frac{2PR}{P + R}. \tag{2-1}$$

上述三个指标在安全视觉中的含义并不完全相同。precision 偏低意味着误报较多，可能造成无效提醒；recall 偏低意味着漏检较多，可能造成风险未被发现；F1 则适合观察二者的折中关系。对于电动车入梯场景，本文更关注 *ebike* 类别的召回率是否在阈值变化下保持稳定。

目标检测结果还受到阈值和非极大值抑制的影响。置信度阈值决定低分候选框是否保留，NMS 阈值决定重叠候选框是否被抑制。若阈值设置过高，系统可能漏掉局部可见的电动车；若阈值设置过低，又可能引入门框、反光或大面积背景误检。因此，阈值并不是简单的工程参数，而是连接检测性能和安全输出稳定性的重要因素。

现代检测器还大量依赖多尺度特征和密集预测。FPN 通过自顶向下路径和横向连接增强不同尺度目标的表达能力 [20]，Focal Loss 则针对密集检测中的正负样本不平衡问题提出了难例加权机制 [21]。Mask R-CNN 展示了检测框架向实例分割扩展的能力 [22]，CenterNet 等 anchor-free 方法把目标表示为关键点或中心点 [23]。这些研究说明，检测器的结构选择会影响候选框数量、分类置信度和定位稳定性。本文不追求复杂检测范式的横向比较，而是选择 YOLO 作为可部署基础，并在部署端对阈值、NMS 和后处理行为做更细的解释。

电梯轿厢目标检测与开放场景检测存在明显差异。开放场景通常目标种类多、背景变化大，评价重点更多放在平均精度；电梯场景类别较少，但背景结构固定且反复出现，误报和漏报往往集中在少数高风险区域。表 2-1 概括了二者的差异。本文采用双目标检测而不是通用多类别检测，正是为了让模型和评价协议聚焦于电动车入梯风险。

表 2-1 电梯场景检测与通用开放场景检测的差异

维度	通用开放场景	电梯轿厢场景
目标类别	类别多，目标分布复杂	类别少，但安全含义强
背景结构	背景变化大	门框、镜面和轿壁反复出现
目标尺度	尺度变化来自远近距离	近景截断和透视畸变明显
评价重点	平均精度和泛化能力	漏检、误检和连续输出稳定性
部署要求	可离线评测为主	需要端侧运行和结果可复查

2.2 YOLO 系列检测器与 YOLOv8 特点

YOLO 系列检测器将目标检测建模为单阶段预测问题，直接从输入图像生成边框、类别和置信度结果，具有结构紧凑、推理流程清晰和部署友好等特点 [7]。与两阶段检测器相比，YOLO 系列更适合实时或准实时场景，这也是其在边缘视觉任务中被广泛采用的重要原因。

YOLO 的发展体现了实时检测器在精度、速度和工程适配之间的持续折中。YOLOv1 首次将检测统一为单次前向预测 [19]，YOLO9000 强化了多尺度训练和层次化类别学习 [7]，YOLOv3 进一步采用多尺度预测和更强的特征提取结构 [24]。随后，YOLOv4 将数据增强、路径聚合和训练技巧系统组合起来 [25]，YOLOX 采用解耦头和 anchor-free 设计改善训练与推理表现 [26]，YOLOv7 和 YOLOv6 则分别从训练技巧、工业部署和实时性角度继续推进单阶段检测器 [27][28]。这些工作共同说明，YOLO 系列的优势不只在模型结构，也在于其可训练、可导出、可部署的完整生态。

从结构上看，YOLO 检测器通常包含 Backbone、Neck 和 Head 三部分。Backbone 负责提取视觉特征，Neck 负责融合不同尺度的特征，Head 负责输出检测框与类别分数。电梯场景中既存在近景人体，也存在局部可见的电动车结构，因此多尺度特征融合对稳定检测具有重要意义。图 2-1 给出了本文采用的 YOLO 双目标检测流程。

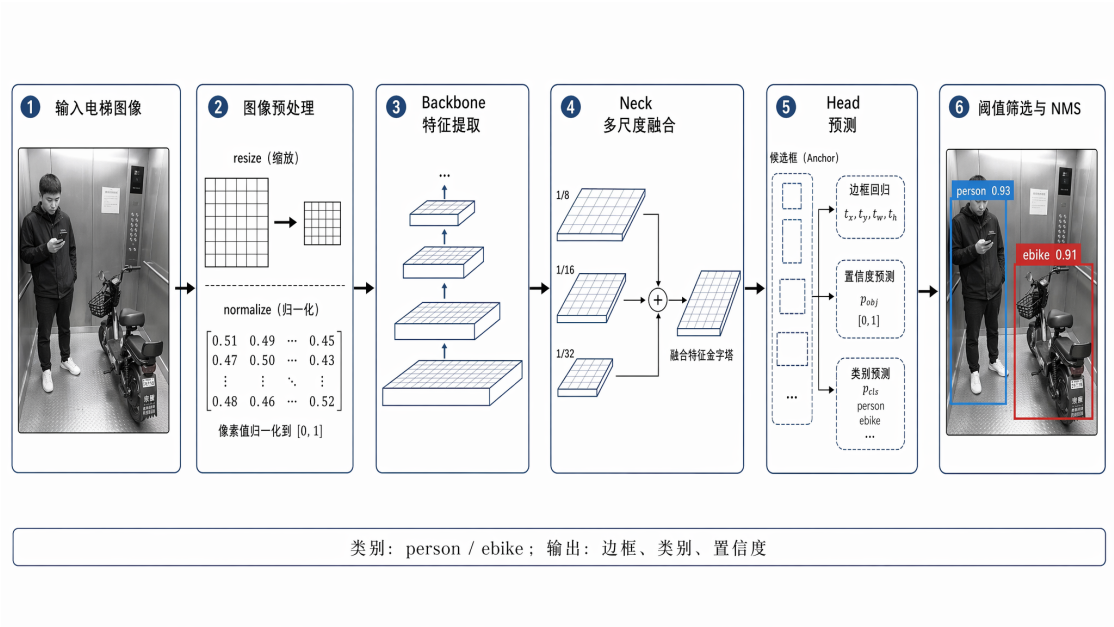

图 2-1 YOLO 双目标检测流程

YOLOv8 进一步采用较轻量的模型尺度和更便于部署的检测头设计。对于本文的双目标任务，模型只需要输出 *person* 与 *ebike* 两类分数，但导出后的张量维度、坐标顺序和类别顺序必须与板端程序保持一致。若板端仍按通用类别数或旧输出格式解释结果，

即使模型权重本身正确，最终检测框也可能出现类别错位或坐标失真。

近年来，DETR 等端到端检测框架将目标检测建模为集合预测问题，减少了手工设计候选框和部分后处理步骤 [29]。这类方法展示了目标检测结构的另一条发展路线，但在本文的边缘开发板场景中，模型部署成熟度、算子支持和实时处理成本同样重要。相比之下，YOLO 系列在工程链路中具有更成熟的导出、编译和板端适配经验，更适合作为本科论文中可复查的边缘安全视觉实现基础。

从部署角度看，YOLOv8 的优势在于主干、特征融合和检测头之间边界清晰，便于检查导出模型的输入输出。但这种清晰结构并不意味着部署可以自动正确完成。训练框架中的预测结果通常已经完成坐标还原、类别筛选和 NMS，而导出模型可能只给出未经封装的张量。板端程序必须明确张量维度、类别数、分数含义和坐标尺度，才能得到与训练端可比较的检测框。

边框质量评价也是 YOLO 部署中必须统一的部分。传统 IoU 只衡量预测框和真实框的重叠程度，而 GIoU 将无重叠情况下的几何关系纳入评价 [30]，DIoU 进一步考虑中心点距离以改善回归优化 [31]。这些指标主要用于训练或离线评价，但在本文中也提示了一个部署事实：如果板端坐标解码、缩放或裁剪不一致，即使类别分数正常，IoU 评价也会明显受损。因此，边框解释一致性是本文第三章接口契约的重要组成部分。

轻量化模型选择需要兼顾精度和设备约束。MobileNet、EfficientNet、EfficientDet 等研究说明了特征提取效率、模型缩放和检测性能之间的关系 [8-10]。在电梯场景中，类别数少并不意味着可以忽略模型表达能力；遮挡和局部可见目标要求模型保留足够多尺度特征。同时，边缘开发板的算力和算子支持又要求模型结构不过度复杂。因此，本文采用轻量 YOLO 模型作为检测基础，并把可部署性纳入模型选择依据。

轻量骨干网络研究为这一选择提供了背景。Inception 结构通过多分支卷积提升表达效率 [32]，ResNet 用残差连接缓解深层网络训练退化 [33]；MobileNet 系列通过深度可分离卷积和倒残差结构显著降低计算量 [34][35]，SqueezeNet 以极小参数量实现接近 AlexNet 的精度 [36]，ShuffleNet V2 总结了移动端网络设计的实际准则 [37]。MnasNet 和 MobileNetV3 进一步把硬件延迟纳入搜索目标 [38][9]，Once-for-All 则尝试通过一次训练适配多种部署约束 [39]。这些研究共同说明，边缘检测不能只看理论 FLOPs，还需要考虑算子、内存访问和目标硬件的真实执行特性。

在本文任务中，YOLO 失效通常不是随机出现的，而是与轿厢空间结构有关。门口区域的垂直边缘可能被误识别为目标边界，镜面反光可能生成重复候选框，电动车只露出车把或车轮时可能造成低置信度候选。由此可见，模型结构、数据分布和后处理阈值共同决定最终效果。后续实验中对分类别召回率和阈值敏感性的关注，正是为了把这些

失效现象转化为可分析指标。

2.3 海思/昇腾类边缘 AI 部署基础

边缘智能强调在靠近数据源的位置完成推理，以降低带宽、隐私和响应时延压力[1]。海思/昇腾类边缘开发板通常通过专用 NPU 执行神经网络推理，模型需要先从训练框架导出为中间表示，再通过 CANN/ATC 等工具编译为设备可执行的 OM 离线模型。图 2-2 展示了本文关注的部署链路。

图 2-2 海思/昇腾类开发板上的 YOLO 部署链路

该链路通常包括五个环节。第一，训练端得到 YOLO 权重；第二，导出 ONNX 中间表示；第三，使用 ATC 编译得到 OM 模型；第四，在板端通过 NPU 运行推理；第五，在应用层完成输出解码、阈值筛选和 NMS 后处理。每个环节都可能改变输出行为。例如，预处理方式不同会改变输入分布，张量读取顺序错误会改变类别语义，后处理阈值不同会改变最终检测数量。

在海思/昇腾类平台上，AIPP、输入尺寸、算子支持和内存布局都会影响模型执行。AIPP 若承担颜色空间转换或归一化操作，则训练端预处理必须与板端配置对应；若预处理在应用层完成，则应用层需要保证输入张量与模型期望一致。OM 模型编译完成后，其输入输出名称、形状和数据类型也需要被记录，否则后续调试很难判断错误来自模型本身还是应用层解释。

深度学习系统研究也表明，模型执行效率不仅由网络本身决定，还由编译器、运行时和硬件体系共同决定。TPU 的系统分析展示了专用加速器在数据中心推理和训练中的性能收益 [40]，TVM 则代表了通过端到端编译优化把模型映射到不同硬件后端的研究方向 [41]。边缘场景与数据中心不同，设备功耗、内存和算子支持更受限制，因此本文更关注“能否在指定板端完整跑通并解释输出”，而不是把通用加速器吞吐作为主要评价指标。

模型压缩和量化是边缘部署中的常见方法。整数推理友好量化、剪枝和知识蒸馏分别从数值表示、结构冗余和知识迁移角度降低模型部署成本 [2-4]。混合精度量化研究进一步表明，不同网络层对量化误差的敏感性并不相同，量化策略会影响最终精度和部署效率 [42]。不过，本文并不把模型压缩作为主要创新，而是关注自训练 YOLO 模型在既定边缘平台上的兼容迁移与行为一致性。

量化研究进一步提示，端侧部署中的数值变化需要通过实测而不是假设处理。Krishnamoorthi 总结了卷积网络推理量化中的校准、缩放和整数计算问题 [43]，Gholami 等对高效神经网络推理量化方法进行了系统综述 [44]，AQD 则直接面向量化目标检测的精度问题 [6]。这些工作说明，检测模型量化后可能在分类分数、边框回归和候选框排序上产生差异。本文虽然不把量化算法作为贡献，但在实验中区分完整板端验证、阈值后验重算和分段计时，正是为了避免把部署后的数值行为简单等同于训练端模型。

2.4 后处理、NMS 与部署参数敏感性

目标检测的最终输出并不完全由神经网络前向结果决定。置信度阈值决定候选框是否进入后续统计，NMS 决定重叠框的保留关系，类别特定的清理规则则可能改变某一类目标的误报和漏报。Soft-NMS 表明，即使只改变传统 NMS 的抑制方式，也可能改善检测结果 [45]。对于本文的电梯场景，NMS 的影响更具体：人和电动车经常在狭窄空间中重叠，电动车局部结构又可能生成多个相邻候选框，过强或过弱的抑制都可能改变最终安全输出。

因此，本文将阈值、NMS 和后处理策略视为部署一致性的一部分，而不是简单的“调参”。如果训练端和板端使用不同置信度阈值，precision、recall 和预测框数量会同步变化；如果 NMS 阈值不同，拥挤重叠区域的候选框保留关系会变化；如果应用层增加类别特定清理规则，某些看似模型误差的问题可能实际来自后处理策略。第五章中的阈值敏感性、NMS 敏感性和后处理消融正是围绕这一逻辑设计。

从论文写作角度看，将后处理写成部署模块也有助于界定贡献。本文不声称改进了 YOLO 训练结构，而是说明在安全视觉落地时，模型权重、阈值、NMS 和应用层清理共

同决定板端输出。这样的界定更符合系统论文常见的评价方式：先给出端到端基准，再通过参数敏感性和消融实验解释关键设计选择。

边缘部署还需要区分“能够运行”和“适合应用”。能够运行表示模型可以被编译、加载并完成推理；适合应用则要求输出稳定、运行口径清晰、失败样本可解释，并且后处理规则能够服务安全需求。本文实验结果中的成功样本数、batch 验证链路耗时、分段计时和阈值敏感性分析，就是为了避免只用“模型已部署”来替代系统层面的可用性判断。

2.5 相邻视觉任务与本文边界

电梯安全视觉可以延伸出多种任务形态，包括人数统计、目标跟踪、姿态估计和视频行为理解等。人数统计研究能够反映轿厢拥挤程度，并已有基于边缘轻量检测器的电梯人数统计系统 [14]；多目标跟踪方法如 DeepSORT 和 ByteTrack 则关注跨帧关联与轨迹保持 [46-47]；姿态估计和视频识别方法可以进一步描述人体关键点或动作模式 [48-49]。这些方向都与电梯安全有关，但它们需要额外标注、时序建模或行为定义。

在连续视频场景中，SORT 使用卡尔曼滤波和匈牙利匹配完成简单在线关联 [50]，DeepSORT 加入外观特征以增强跨帧关联 [46]，ByteTrack 则强调低分检测框在跟踪中的利用价值 [47]。这些工作说明，视频稳定性往往需要检测器和时序逻辑共同保证。本文没有把完整多目标跟踪作为主体任务，而是在代表性视频片段中观察连续输出保持、闪烁和分段耗时，避免在缺少逐帧标注的情况下过度报告视频级精度。

本文没有把上述任务全部纳入主体实验，而是将研究范围限定在 *person* 与 *ebike* 双目标检测及其边缘迁移上。这样处理有两个原因。第一，电动车入梯治理首先需要稳定回答“人和电动车是否被检测到”，这是后续计数、跟踪和行为判断的基础。第二，本科论文需要保证实验结论可复查，如果同时扩展到跟踪或动作识别，就需要额外的视频级人工标注和时序评价协议。本文因此将代表性视频片段作为运行状态和输出稳定性的补充观察，而不把它扩展为完整视频理解任务。

2.6 部署一致性问题

部署一致性是指同一检测模型经过格式转换和设备迁移后，其输入语义、输出语义和后处理行为仍保持可比较状态。对于普通离线实验，研究者往往只关心最终 mAP；但在安全视觉系统中，类别错位、边框漂移、阈值变化和运行时异常都可能导致预警结果变化。因此，部署一致性应被视为方法的一部分，而不只是实验环境说明。

本文将一致性问题分为四类。第一是类别一致性，即训练端、ONNX 端、OM 端和

板端对 *person* 与 *ebike* 的类别顺序解释一致。第二是边框解释一致性，即坐标归一化、缩放和裁剪方式在评价设计上保持可比较。第三是阈值稳定性，即置信度阈值和 NMS 参数在不同阶段含义一致。第四是运行时可靠性，即模型能够在边缘设备上稳定执行，并记录成功样本数、失败样本数、batch 端到端耗时和分段计时等运行状态。

这四类一致性之间存在依赖关系。类别一致性是结果解释的前提，若类别顺序错误，后续 precision 和 recall 都失去意义；边框解释一致性是 mAP 和 IoU 评价的前提，若坐标还原错误，模型可能被误判为定位能力不足；阈值稳定性决定安全输出是否依赖偶然参数；运行时可靠性则决定一次实验是否能够代表真实设备行为。因此，本文将一致性评价放在方法章和实验章之间，作为连接模型迁移与实验结论的关键桥梁。

已有部署研究已经指出，深度模型从训练框架迁移到生产环境时，格式转换、算子支持和运行时差异会引入额外风险 [5-6]。在电梯安全视觉中，这类风险会进一步受到场景因素放大。例如，反光和门口结构可能使候选框分数接近阈值，局部可见电动车可能使边框定位更敏感，拥挤重叠则可能改变 NMS 结果。因此，本文后续方法章将围绕接口契约和分阶段验证建立部署一致性分析框架。

2.7 相关工作小结

综上，YOLO 系列检测器为电梯双目标检测提供了高效基础，边缘 AI 平台为本地安全预警提供了硬件条件，模型压缩与部署研究则说明了端侧推理的可行性。然而，现有工作往往分别讨论检测精度或边缘部署，较少把训练权重、ONNX 中间表示、OM 离线模型和板端后处理放入同一评价框架。本文围绕这一缺口展开：在电梯轿厢场景中，以行人与电动车双目标检测为任务载体，建立面向海思/昇腾类边缘开发板的兼容迁移与一致性评价方法。

第三章 YOLO 双目标检测模型的边缘兼容迁移方法

本章给出本文的核心方法。与只描述模型训练或只说明板端运行不同，本文把 YOLO 双目标检测模型从训练权重迁移到海思/昇腾类边缘开发板的全过程视为一个需要保持语义一致的系统链路。方法目标是在电梯轿厢场景中，使 *person* 与 *ebike* 两类目标的输入、类别、边框、阈值和运行状态都具备可检查的契约。

3.1 总体技术路线

图 3-1 给出了本文方法的总体流程。训练阶段得到的 YOLO 双目标检测权重先经过类别数与检测头适配检查，再导出为 ONNX 中间表示；随后通过 ATC 编译得到边缘设备可执行的 OM 模型；最后在板端完成 NPU 推理、输出解码、阈值筛选和非极大值抑制，并与统一评测协议下的结果进行一致性分析。

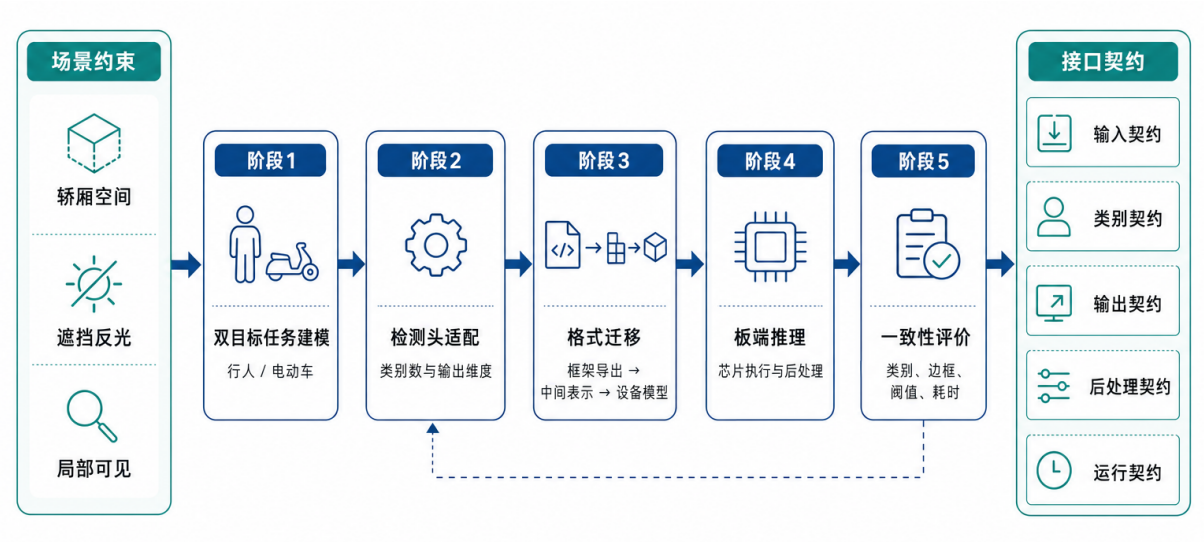

图 3-1 YOLO 双目标检测模型的边缘兼容迁移流程

该流程包含三层含义。第一，模型层需要保证检测头输出与双目标任务一致，避免类别数或类别顺序错误。第二，格式层需要保证 PyTorch、ONNX 和 OM 之间的输入输出张量语义一致。第三，应用层需要保证板端后处理逻辑与训练端评价逻辑可比较。只有三层同时满足，边缘设备端的检测指标才具有解释意义。

本文将该流程设计为“先检查语义，再检查数值，最后检查运行”的顺序。语义检查包括类别数量、类别顺序和输出张量维度；数值检查包括边框坐标、置信度范围和 NMS 后检测数量；运行检查包括模型加载、推理成功率、验证链路端到端耗时和关键分段耗时。这样的顺序能够避免在基础语义尚未对齐时直接讨论 mAP，也能避免把 batch 外围链路耗时误解为模型执行阶段耗时，从而提高实验结论的可信度。

3.2 迁移接口契约

为避免把部署问题简化为“模型能否运行”，本文将迁移链路抽象为接口契约。接口契约不是额外算法模块，而是贯穿训练、导出、编译和板端运行的约束集合。

接口契约的作用是把容易隐含在代码和配置中的约束显式化。对于本文任务而言，每一类契约都对应一个具体问题：输入契约回答“同一张电梯图像是否以相同方式进入模型”，类别契约回答“*person* 与 *ebike* 是否被同一语义解释”，输出契约回答“检测头张量是否被正确解码”，后处理契约回答“阈值和 NMS 是否改变安全输出”，运行契约回答“实验结果是否来自可复查的板端执行过程”。这五个问题共同决定板端指标是否具有论文意义。

本文采用五类迁移契约：输入契约约束输入尺寸、颜色通道、归一化和缩放方式，避免分数整体漂移或小目标漏检；类别契约约束类别数量、类别顺序和标签名称，避免 person 与 ebike 语义错位；输出契约约束检测头张量维度、坐标格式和置信度含义，避免边框位置错误或分数解释错误；后处理契约约束置信度阈值、NMS 阈值和类别处理方式，避免检测数量、重复框和漏检率异常变化；运行契约约束模型文件、板端二进制、成功样本数、端到端处理耗时和分段计时，避免结果不可复查或运行口径混淆。

输入契约主要解决训练端和板端图像进入模型前是否一致的问题。电梯图像常包含强反光和大面积背景结构，若缩放、填充或颜色通道处理不一致，模型对局部电动车结构的响应会发生变化。类别契约主要解决双目标任务的语义一致性问题。本文只保留 *person* 与 *ebike* 两类，类别顺序必须在训练配置、导出模型和板端后处理中保持一致。

输出契约是 YOLO 部署中最容易被忽视的部分。训练端框架通常自动完成坐标解码和结果封装，而板端程序需要显式读取输出张量并解释其维度。如果坐标中心点、宽高、左上右下角或置信度分数组合方式被错误理解，最终结果会表现为边框漂移、类别分数异常或检测数量变化。

为使契约可以被执行，本文在迁移链路中采用逐项检查方式。导出 ONNX 后，先检查输入尺寸和输出张量形状是否符合双目标检测设置；编译 OM 后，检查板端程序读取的输出数量和张量维度是否与导出阶段一致；运行验证集时，检查成功样本数、分类别预测数和分类别 TP/FP/FN 是否处于合理范围。若某一项出现异常，优先回到对应契约定位问题，而不是直接调整阈值掩盖错误。

分阶段验证策略强调每一阶段只解决一个主要问题：训练端关注模型是否具备基础检测能力，输出权重文件与验证集指标；导出端关注输入输出形状和类别维度是否保留，输出中间表示与张量检查结果；编译端关注 OM 模型是否生成且算子是否兼容，输出离线模型与编译记录；板端关注推理成功率和后处理结果，输出检测框、分类别指标

和运行时信息。分阶段验证可以降低排错复杂度，避免在板端结果异常时无法判断问题来源。

3.3 关键一致性环节

3.3.1 输入预处理对齐

输入预处理对齐要求训练端、导出端和板端使用相同的输入尺寸与图像变换语义。对于固定视角电梯场景，目标尺度分布相对稳定，但近景人体和局部电动车会使边缘区域信息非常重要。因此，预处理不应仅追求图像尺寸匹配，还需要保证缩放比例、填充区域和坐标还原方式能够被后处理正确反推。

3.3.2 类别语义对齐

类别语义对齐是双目标任务迁移中最基础的契约。本文只包含 *person* 与 *ebike* 两个类别，看似比通用多类别检测更简单，但类别数减少并不意味着类别解释可以放松。训练配置、导出模型、板端标签表和后处理代码必须使用相同类别顺序；否则，即使检测框位置正确，最终报警语义也可能被反转。

在实验解释中，分类别 TP、FP、FN 统计也被用作类别契约的外部检查。若板端程序把类别维度读取错误，*person* 与 *ebike* 的预测数量、召回率和 mAP@0.5 会出现与场景经验明显不符的异常。因此，分类别指标不仅衡量检测性能，也用于判断迁移后的语义解释是否成立。

3.3.3 输出张量语义对齐

输出张量语义对齐要求板端程序明确知道 YOLO 检测头输出中每一维的含义。本文关注的双目标检测只有两个类别，但这反而要求类别维度更清晰：如果板端按错误类别数读取张量，类别分数的位置会发生偏移；如果按错误坐标格式解释边框，IoU 指标会下降。本文将输出张量检查作为迁移流程中的必要步骤，以保证后续实验结果能够对应到真实检测行为。

3.3.4 后处理一致性

后处理一致性包括置信度筛选和 NMS 两部分。置信度阈值决定候选框进入最终结果的机会，NMS 决定重叠候选框的保留关系。电梯场景中的反光、门口结构和局部可见电动车会产生大量边界候选框，因此阈值稳定性直接影响安全输出。本文在实验章中

通过阈值敏感性分析观察不同置信度阈值下 precision、recall、F1 和电动车召回率的变化。

后处理既可以在模型图中完成，也可以在应用层完成。若后处理前移到模型图中，优点是板端应用更简单，缺点是阈值和 NMS 策略调整不够灵活；若后处理保留在应用层，优点是便于针对安全场景调整阈值，缺点是应用层必须正确实现坐标解码和候选框抑制。本文采用应用层后处理思路，并通过契约方式约束其输入、阈值和输出含义。

3.3.5 运行时可靠性

运行时可靠性要求设备端不仅能够加载 OM 模型，还能够完成完整验证集推理并记录成功样本数、失败样本数、验证链路端到端耗时和关键分段耗时。对于安全视觉系统，单张图像推理成功不足以说明系统可用；只有在统一数据集上稳定执行，并能说明耗时指标属于哪一段链路，设备端结果才具备评价意义。

运行时可靠性还需要关注异常样本处理。若某些图像推理失败，实验报告应区分模型检测错误和运行失败；若大量样本触发兜底路径或超时，端到端耗时也需要与成功样本数一起解释。本文在结果章报告成功样本数、失败样本数、batch 图像验证链路平均单图处理耗时和分段计时结果，目的就是避免只用精度指标描述一个可能不稳定的板端运行过程。

3.4 一致性评价方法

本文从类别语义、边框解释、阈值行为和运行时状态四个维度评价部署一致性。类别语义关注不同阶段是否输出相同类别含义；边框解释关注坐标还原、IoU 评价和定位漂移的评价设计；阈值行为关注置信度阈值变化对 precision、recall 和 F1 的影响；运行时状态关注成功样本数、失败样本数、端到端处理耗时和分段计时。四类维度共同构成本文的评价框架。

四类评价维度各有侧重：类别一致性通过类别顺序和分类别 TP/FP/FN 判断 person 与 ebike 语义是否稳定；边框解释通过 IoU、边框漂移设计和 NMS 后数量判断定位变化是否影响检测结果；阈值稳定性通过多阈值 P/R/F1 与 ebike recall 判断安全输出是否依赖单一阈值；运行时可靠性通过成功样本数、失败样本数、端到端耗时和分段计时判断板端验证是否完整可复查，并区分 batch 外围链路与模型执行阶段。

若条件允许，最完整的一致性实验应在 PyTorch、ONNX、OM 和板端四个阶段对同一批样本逐一匹配输出。考虑到本科论文工作量和已有实验范围，本文实验章重点报告板端完整验证集结果、分类别结果和阈值敏感性后验重算结果，并将逐样本跨阶段匹配

作为后续扩展方向。这样的处理使当前结论与已有实验材料保持一致。

样本级匹配的基本思路是：对于同一张输入图像，先按类别过滤候选框，再按 IoU 从高到低匹配同一目标，最后比较不同阶段的类别、坐标和分数差异。若类别一致但 IoU 明显下降，说明主要问题可能来自坐标还原或 NMS；若 IoU 接近但类别不同，说明问题更可能来自类别顺序或输出维度解释；若同一阶段检测数量明显变化，则需要检查阈值和候选框抑制逻辑。该方法使跨阶段一致性从抽象概念转化为可执行的比较过程。

当结果出现异常时，本文先判断异常表现属于类别、边框、阈值还是运行状态，再回到对应契约检查。若类别大量错位，优先检查类别顺序和输出张量维度；若边框整体偏移，优先检查缩放、填充和坐标解释；若检测数量突变，优先检查 conf、NMS 和类别清理策略；若时延异常升高，优先检查板端执行路径、输入输出复制和资源状态。这种排查顺序把部署问题转化为可复查的技术项，使方法具有可复用性。

3.5 本章小结

本章提出了 YOLO 双目标检测模型的边缘兼容迁移方法。该方法以接口契约为核心，将输入预处理、类别配置、输出张量、后处理参数和运行状态纳入同一评价框架。与单纯报告模型精度相比，本文方法更强调训练端模型进入海思/昇腾类边缘开发板后的行为可解释性和结果可复查性。

第四章 数据集、场景复杂性与评测协议

4.1 任务与数据组织

本文实验围绕电梯轿厢内 *person* + *ebike* 双目标检测展开。图像验证集用于评价检测精度，代表性视频片段用于观察连续场景稳定性，板端运行输出用于分析模型迁移后的阈值行为、运行状态和分段耗时。难例不作为独立分类实验，也不额外建立人工分组；本文只在讨论中使用场景复杂性因素解释模型在真实轿厢中为什么会出现漏检、误检或边框漂移。

为了使实验结论服务于第一章提出的问题链，本文将评价目标拆分为六个具体问题：第一，模型迁移到板端后是否能完整处理验证集并保持双目标检测能力；第二，*person* 与 *ebike* 的分类别指标是否符合任务语义；第三，置信度阈值变化是否会显著改变安全输出；第四，NMS 与应用层后处理是否影响最终候选框；第五，代表性视频片段中输出是否保持连续稳定；第六，batch 图像验证耗时、单帧核心处理耗时和模型执行阶段耗时是否能够被明确区分。第五章的结果组织即围绕这些问题展开。

4.2 场景复杂性因素

电梯场景的困难之处来自封闭空间、固定视角和安全响应要求的叠加。轿厢内常见的高亮区域、门框结构、局部目标、近距离重叠、尺度变化和暗部区域都会改变目标轮廓、类别分数或候选框排序。本文不把这些因素整理成人工标签，也不按人工分组报告独立指标；它们只用于解释阈值、NMS、后处理和视频稳定性实验中的现象。

本文使用的证据可以分为四类。第一类是 720 张图像验证集，用于统计总体精度、分类别精度和板端 batch 验证耗时；第二类是基于既有板端检测输出的阈值后验重算，用于观察同一批输出在不同安全阈值下的稳定性；第三类是 batch 图像复查和连续视频处理中的分段计时输出，用于区分 batch 端到端耗时、单帧核心处理和模型执行阶段；第四类是代表性视频片段，用于观察连续帧中的漏检、闪烁和边框抖动。上述证据共同回答本文核心问题：同一 YOLO 模型迁移到 OM 和板端运行后，是否仍保持可解释、可复查的检测行为。

上述场景因素不要求额外训练识别模型，也不改变本文的评价单位。这样可以避免论文主线发散，同时保留电梯场景相对于通用检测任务的特殊性。

4.3 评测指标设计

本文评测指标分为检测精度、部署一致性和运行时性能三类。检测精度包括 precision、recall、F1 和 mAP@0.5，用于描述模型在验证集上的基础识别能力。部署一致性主要通过分类别统计、阈值敏感性和运行状态进行分析；跨阶段逐样本边框漂移属于更完整的一致性实验设计，在本文中作为后续扩展。运行时性能包括 batch 图像验证链路端到端单图处理耗时、成功处理样本数和分段计时，用于判断系统运行结果是否可复查。

具体指标围绕三个问题组织。检测能力由 precision、recall、F1 和 mAP@0.5 描述；类别语义由 person 与 ebike 的 TP、FP、FN、recall 和 mAP@0.5 检查；部署行为由多阈值 F1、类别召回、成功样本数、端到端耗时和分段计时共同说明。跨阶段 IoU 漂移属于更完整的一致性实验设计，本文只在方法层面保留其评价方式。

4.4 实验协议

为保证实验结果可比较，本文采用统一协议。首先，所有图像级指标均在同一验证集上统计，并统一保留三位小数。其次，阈值敏感性实验只改变置信度阈值，其余参数保持不变。再次，分段计时实验必须明确运行模式，区分 batch 图像验证链路和连续视频链路。最后，视频场景分析只使用连续场景片段表述，不在正文中展开数据文件位置，也不在缺少逐帧人工标注的条件下计算视频级 precision 或 recall。

各实验只改变一个主要变量。基线验证固定验证集、类别顺序和输入尺寸；阈值敏感性只改变置信度阈值；NMS 敏感性只改变 IoU 阈值；后处理消融只改变电动车清理策略；视频稳定性只改变平滑窗口；分段计时则固定模型、二进制和阈值设置，只比较 batch 端到端、单帧核心处理和模型执行阶段。该协议体现了本文的研究重点：实验不追求数量堆叠，而是围绕 YOLO 模型的边缘部署一致性建立可复查的评价流程。

4.5 场景复杂性与部署误差的关系

场景复杂性与部署一致性之间存在直接联系。高亮区域和暗部区域主要影响类别置信度，容易在阈值扫描中表现为召回率波动；轿厢边界和门框结构主要影响边框回归和 NMS，容易在边框解释评价中表现为 IoU 下降；近距离重叠则同时影响类别排序和候选框抑制，可能造成不同阶段输出数量不一致。

因此，本文在分析实验结果时采用“指标 + 场景解释”的方式。若 mAP@0.5 下降，需要进一步判断下降来自类别分数变化还是边框定位变化；若视频片段出现闪烁，需要结合阈值敏感性判断是否存在置信度边界问题。通过这种方式，场景复杂性服务于部署一致性分析，而不是另起一条难例创新主线。

4.6 数据集划分与可复查性要求

为保证实验结果能够被复查，数据划分需要保持清晰。本文使用的图像验证集固定为 720 张图像，用于报告板端总体指标和分类别指标。该验证集在正文中只描述其规模、类别和用途，不展开本地文件组织细节。

数据可复查性包括三层含义。第一，样本数量可复查，即实验表格中的样本数与指标来源一致。第二，类别统计可复查，即 person 与 ebike 的真实目标数、预测数、TP、FP、FN 能够对应到评测结果。第三，运行状态可复查，即成功样本数、失败样本数和端到端耗时能够说明板端验证是否完整执行。

对于视频片段，在缺少人工逐帧标注的条件下，本文不计算视频级 precision 或 recall，而只使用机器侧统计描述输出稳定性。这样可以保证评价指标与可用证据相匹配。

4.7 跨阶段一致性实验设计

跨阶段一致性实验的理想形式是选取同一批输入样本，分别在训练端、ONNX 端、OM 端和板端运行，再对输出结果进行逐样本匹配。匹配时首先按照类别和 IoU 阈值确定同一目标，然后统计类别一致率、平均边框 IoU、置信度差异和最终检测数量差异。该实验能够直接衡量模型迁移过程是否改变检测行为。

在实际执行时，应避免同时改变多个变量。输入图像、预处理方式、置信度阈值和 NMS 阈值需要固定，唯一变化的是推理阶段。若发现输出差异，再根据第三章的误差定位表检查类别契约、坐标契约或后处理契约。这样，跨阶段实验不仅给出结果，还能帮助定位问题来源。

本文已经形成完整板端验证结果，但训练端、ONNX 端、OM 端和板端的逐样本统一对比仍属于研究局限。因此，本节仅给出跨阶段一致性实验的评价方式，当前实证结果仍以板端完整验证、阈值后验重算和分段计时为主。

4.8 实验结果呈现原则

为了保证实验结果可信，本文区分实测结果、后验重算结果和方法性评价设计。已有完整证据支撑的内容，如 720 张图像的板端验证结果，可以写入实验结果表并进行结论分析；基于既有检测输出重新筛选得到的阈值敏感性结果，可以作为补充实验；跨阶段逐样本对齐尚不具备完整数值表，因此只用于说明评价方法和研究局限。

这一处理符合实验研究的基本要求。工程实践中存在日志、脚本、视频和人工观察等多种材料，只有区分证据强度，才能避免把经验观察混同为定量结论。本文将图像验

证集用于计算检测指标，将视频片段用于辅助观察稳定性，将场景复杂性描述用于解释误差来源。

通过这种方式，本文的实验结论只建立在可复查证据之上，跨阶段对齐则作为研究局限与扩展方向处理。

4.9 本章小结

本章给出了本文的数据组织方式、场景风险分类、评测指标体系和实验协议。场景风险分类服务于误差解释和实验分组，评价重点则集中在 YOLO 双目标检测模型在海思/昇腾类边缘开发板上的部署一致性。

第五章 实验结果与分析

本章围绕第四章定义的实验协议，对 YOLO 双目标检测模型在边缘设备端的表现进行分析。实验重点不是单纯报告一个离线精度数值，而是回答七个评价问题：第一，模型迁移到板端后是否能在完整验证集上保持稳定检测能力；第二，分类别输出是否符合 *person* + *ebike* 双目标任务语义；第三，不同置信度阈值下安全输出是否稳定；第四，NMS 参数变化是否会改变重叠候选框的保留关系；第五，应用层后处理策略是否影响电动车误报与召回；第六，代表性视频片段中连续输出是否稳定；第七，batch 图像验证链路耗时、单帧核心处理耗时和模型执行阶段耗时是否能够被清楚区分。

5.1 实验设置与评价范围

本文实验使用同一轻量 YOLO 双目标检测模型，类别为 *person* 与 *ebike*。图像验证集包含 720 张电梯轿厢图像，评价指标包括 precision、recall、F1、mAP@0.5、分类别指标和板端运行状态。板端推理使用海思/昇腾类边缘开发板完成，模型以 OM 离线模型形式运行，后处理包含置信度筛选和 NMS。

实验前先确认板端验证环境、模型文件、应用程序和数据集均处于可复查状态。完整验证集已完成板端实测，阈值敏感性分析采用既有板端检测输出进行后验筛选重算；NMS 和后处理消融采用同一板端 campaign 协议，保证只有一个参数变化；分段计时实验则使用新增计时埋点对小样本 batch 图像验证和代表性视频片段进行补充复查。

阈值后验重算的依据是板端检测输出中保留了每个候选框的类别、置信度和坐标，同时每张图像具有对应真实标注。因此，在原始候选阈值低于待分析阈值的前提下，可以通过重新筛选候选框并按 IoU@0.5 匹配真实框，得到不同置信度阈值下的 precision、recall 和 F1。该做法不改变模型推理结果，只改变结果解释阈值，适合用于分析安全输出对阈值选择的敏感程度。

本章评价问题与证据形式保持一一对应。RQ1 使用 720 张图像完整验证总体指标回答板端完整验证是否可执行且具备检测能力；RQ2 使用分类别 TP、FP、FN、recall 和 mAP@0.5 检查两类目标是否保持正确语义；RQ3 使用 0.20–0.40 置信度阈值后验重算分析安全输出稳定性；RQ4 和 RQ5 分别使用固定 score 后改变 NMS 阈值、改变电动车清理策略的板端 campaign；RQ6 使用代表性视频片段和平滑窗口对比观察连续输出；RQ7 使用 50 张图像 batch 复查与连续视频分段计时解释运行时指标。这样的组织方式用于保证每个实验结论都能追溯到具体数据类型，避免把不同口径的指标混为一谈。

5.2 RQ1：板端完整验证集是否保持检测能力

表 5-1 给出了 720 张图像验证集上的总体结果。所有样本均在板端完成处理，成功处理样本数为 720，失败样本数为 0。总体 precision 为 0.901，recall 为 0.923，F1 为 0.912，mAP@0.5 为 0.910。板端 batch 图像验证链路端到端平均单图处理耗时约为 1119.510 ms。

表 5-1 边缘设备端总体检测结果

指标	数值
验证图像数	720
成功样本数	720
失败样本数	0
precision	0.901
recall	0.923
F1	0.912
mAP@0.5	0.910
batch 端到端单图处理耗时/ms	1119.510

该结果说明，自训练 YOLO 模型经过 ONNX 导出、ATC 编译和 OM 模型部署后，能够在边缘设备上完成完整验证集处理。对于本文而言，这一结果的意义不仅是给出检测精度，更重要的是表明迁移链路具备完整执行能力，为后续分类别分析、阈值敏感性分析和运行时口径拆解提供基础。

需要特别说明的是，表 5-1 中的 1119.510 ms 是 batch 图像验证链路端到端单图处理耗时，包含图像输入、媒体链路、预处理、模型执行、后处理、结果写出等环节。该数值不能直接等同于 OM 模型执行阶段耗时，也不能用于推断连续视频链路的帧间耗时。本文后续通过分段计时实验单独讨论这一问题。

5.3 RQ2：分类别输出是否符合任务语义

表 5-2 给出了 *person* 与 *ebike* 两类目标的检测结果。电动车类别的 mAP@0.5 为 0.952，召回率为 0.961，高于行人类别的 0.869 和 0.888。这说明在当前验证集上，模型对电动车目标具有较强识别能力，而行人类别受到遮挡、截断和多人重叠等因素影响更明显。

表 5-2 边缘设备端分类别检测结果

类别	GT	Pred	TP	FP	FN	recall	mAP@0.5
person	776	794	689	105	87	0.888	0.869
ebike	720	739	692	47	28	0.961	0.952

图 5-1 对总体指标和分类别指标进行了可视化。可以看到，整体四项指标均处于 0.90 左右，说明板端输出具备基本检测能力；分类别结果中，电动车类别的召回率和 mAP@0.5 均高于行人类别，符合电动车结构特征相对显著、行人更容易受近景截断和多人重叠影响的场景观察。

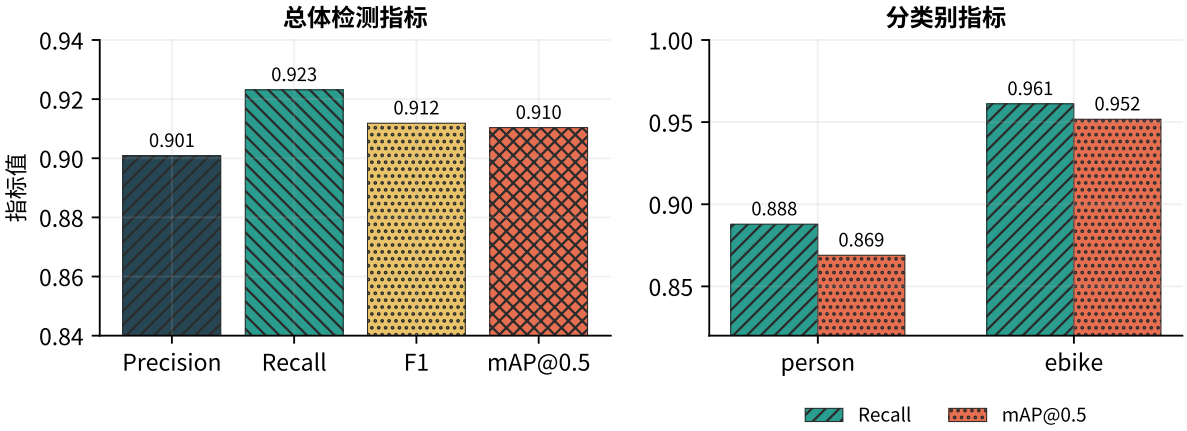

图 5-1 边缘设备端总体指标与分类别指标

从部署一致性角度看，分类别统计还可以反向验证类别契约是否成立。如果类别顺序在导出或板端解析过程中发生错位，*person* 与 *ebike* 的 TP、FP、FN 分布会出现明显异常，难以形成当前这种与场景经验一致的分类别结果。因此，分类别指标不仅是性能评价，也是部署语义检查的一部分。

5.4 RQ3：阈值变化是否影响安全输出

为分析置信度阈值对安全输出的影响，本文在既有板端检测输出基础上进行后验筛选重算。由于原始板端运行使用的候选阈值低于本节扫描阈值，本文可以在不重新推理的条件下，分别保留置信度不低于 0.20、0.25、0.30、0.35 和 0.40 的检测框，并按 IoU@0.5 重新统计 precision、recall 和 F1。表 5-3 给出了结果。

表 5-3 置信度阈值敏感性后验重算结果

conf	precision	recall	F1	ebike recall	person recall
0.20	0.911	0.919	0.915	0.957	0.884
0.25	0.921	0.916	0.919	0.957	0.878
0.30	0.925	0.912	0.919	0.956	0.872
0.35	0.935	0.909	0.922	0.956	0.866
0.40	0.942	0.903	0.922	0.953	0.857

结果显示，随着置信度阈值从 0.20 提高到 0.40，总体 precision 从 0.911 提升到 0.942，recall 从 0.919 下降到 0.903，F1 保持在 0.915–0.922 区间。电动车召回率在五个阈值下

保持在 0.953 以上，说明在当前验证集和板端输出条件下，电动车检测对这一阈值区间相对稳定。行人召回率随阈值提高从 0.884 降至 0.857，说明行人类别中存在更多接近阈值边界的候选框。

图 5-2 展示了各指标随阈值变化的趋势。precision 随阈值提高而上升，recall 缓慢下降，F1 保持相对平稳；分类别召回率中，*ebike* 曲线较平，*person* 曲线下降更明显。这一结果表明，阈值选择不能只依据总体 F1，还需要考虑不同类别在安全任务中的风险权重。

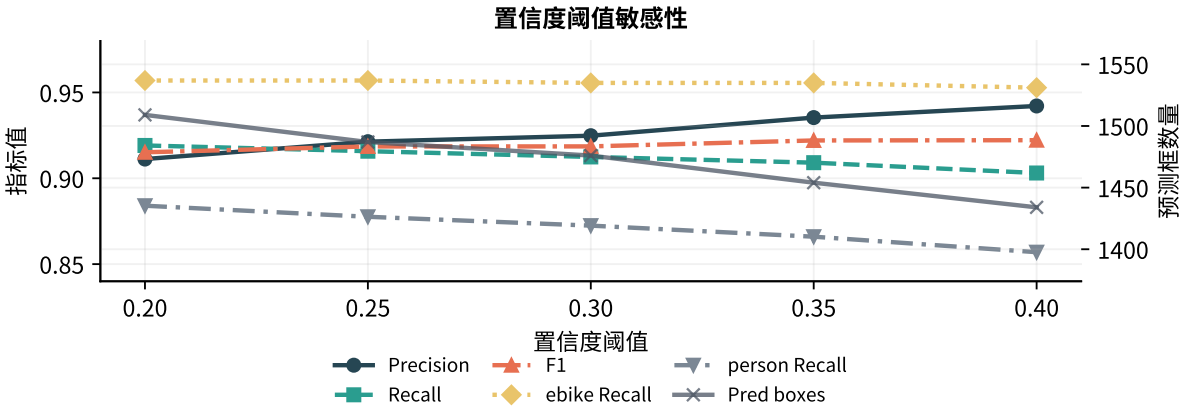

图 5-2 置信度阈值敏感性曲线

需要注意的是，阈值敏感性后验重算并不等同于重新训练模型，也不改变板端推理输出。它的作用是回答“同一批板端输出在不同安全阈值下是否稳定”。因此，该实验不能说明模型在所有场景和所有阈值下都稳定，但可以增强本文关于当前验证集内阈值行为可复查的证据链。

5.5 RQ4：NMS 参数如何影响候选框保留

NMS 参数敏感性实验用于观察重叠候选框的保留关系是否依赖单一 IoU 阈值。本文设计的实验固定模型、验证集、置信度阈值和后处理策略，只改变 NMS 阈值，取值为 0.35、0.45 和 0.55。低 NMS 阈值会更强地抑制重叠框，可能减少重复框但增加遮挡区域漏检；高 NMS 阈值会保留更多相邻框，可能提高局部目标召回但增加误报和重复框。

该实验与阈值后验重算不同，需要重新运行板端推理，因为 NMS 在板端应用层已经影响最终输出。为避免把不同代码版本或模型文件混入比较，三组实验需要使用同一 OM 模型、同一板端二进制和同一验证集切分，并记录模型 md5、二进制 md5、score、NMS 和 campaign 标识。正文只接受能够回溯到 `summary.json`、`detections.jsonl` 和 `per_image.csv` 的数值；若某组 campaign 尚未完成，则不在表中填入估计值。

本实验的论文作用是补充说明电梯轿厢中人车重叠、近景截断和局部电动车结构对 NMS 的敏感性。与通用检测论文中只报告单一 NMS 设置相比，边缘安全视觉需要说明所选参数不是偶然有效。后续若三组 campaign 产物齐备，本文的图表脚本会生成 `fig_chap05_nms_sensitivity`，展示分类别 F1、FP、FN 和预测框数量随 NMS 变化的趋势。

5.6 RQ5：后处理策略消融如何界定部署模块作用

应用层后处理消融用于回答一个容易混淆的问题：板端输出变化究竟来自模型权重，还是来自模型之后的候选框清理逻辑。本文将电动车误检清理策略显式暴露为 `full`、`safe` 和 `off` 三种模式。其中，`full` 表示完整启用误检清理，`safe` 表示只启用较保守的重复框和明显条带清理，`off` 表示关闭电动车类别特定清理。默认 `auto` 模式保持当前板端行为，即 batch 评价路径保留更原始的 `safe` 输出，视频 file 路径使用更面向展示的 `full` 输出。

该消融不是训练消融，也不表示本文提出了新的检测网络结构。它的作用是把板端应用层规则从“隐含工程细节”转化为可以复查的部署模块。若三组策略在同一验证集上的 FP、FN 和 `ebike recall` 差异明显，则说明安全输出不仅由模型权重决定，也受到后处理规则影响；若差异很小，则说明当前电动车检测结果主要由模型分数和 NMS 决定。无论哪一种结果，都能够帮助论文更准确地解释部署一致性。

为了保证证据边界，本文不使用手工挑选案例替代完整验证集统计，也不把视频片段中的肉眼观察写成图像级精度。后处理消融数值必须来自同一 campaign 规范下的板端输出，并由统一评测脚本复算。图表脚本在统一前缀下的 `cleanup_full`、`cleanup_safe` 和 `cleanup_off` 三组 artifact 同时存在时生成后处理消融图。

5.7 RQ6：代表性视频片段如何补充稳定性观察

除图像验证集外，本文还使用代表性视频片段观察连续场景下的输出稳定性。机器侧统计显示，在一个约 14.58 s、437 帧的代表性片段中，系统能够记录原始检测输出、筛选后输出、分段计时和运行资源信息。该类视频结果不用于计算 precision 或 recall，因为缺少逐帧人工标注；其作用是观察连续帧中的检测保持、闪烁、漏检现象和运行时状态。

视频稳定性实验固定模型、score 和 NMS，只改变平滑窗口，重点比较窗口 1 与窗口 5。前者接近无平滑或最小平滑，能够暴露单帧检测分数波动；后者代表默认连续输出策略，更接近真实展示链路。两组结果需要分别记录处理耗时、模型执行耗时、检测

保持率、闪烁次数和连续漏检片段。若没有逐帧人工标注，本文只将其写作连续输出稳定性观察，不扩展为视频级检测精度。

视频片段分析表明，安全视觉系统的最终输出不仅取决于单帧检测框，还取决于后处理策略和连续帧稳定性。即使图像级指标较高，若连续视频中目标框频繁出现和消失，仍会影响预警体验。因此，本文将视频分析作为图像验证集的补充，而不把它替代为主要定量指标。

5.8 RQ7：分段计时如何解释运行时口径

为避免把 batch 图像验证链路端到端耗时误解为 OM 模型执行阶段耗时，本文补充了板端分段计时实验。该实验在应用程序中记录单帧处理、模型执行、预处理、后处理和渲染等分段字段。其中，端到端字段表示 batch 图像验证链路单图耗时，单帧处理字段表示核心处理路径耗时，模型执行字段表示包围 OM/NPU 模型执行调用的工程计时。

表 5-4 给出了本轮分段计时结果。50 张图像 batch 复查中，`elapsed_ms` 均值为 1123.300 ms，与 720 张完整验证集中的 1119.510 ms 处于同一数量级；但同一实验中的 `frame_proc_ms` 均值为 21.459 ms，`model_execute_ms` 均值为 8.208 ms。代表性视频片段中，`frame_proc_ms` 均值为 11.870 ms，`model_execute_ms` 均值为 8.407 ms。

表 5-4 板端分段计时结果

运行模式	样本规模	elapsed	frame_proc	model_execute
batch 图像验证	50 张图像	1123.300	21.459	8.208
连续视频处理	437 帧	–	11.870	8.407

图 5-3 使用对数坐标展示上述差异，图中虚线表示 30 fps 视频约 33.3 ms 的帧间隔。可以看到，batch 端到端耗时与单帧核心处理、模型执行阶段不在同一数量级。这说明旧有 1119.510 ms 指标主要用于描述 batch 图像验证路径的端到端成本，而不应解释为模型执行阶段耗时。代表性视频路径下的单帧核心处理耗时低于 33.3 ms，说明该按源帧节奏回放条件下的处理计时与连续帧输入节奏相容；但该结论仍属于运行时分段证据，不替代带人工标注的图像验证集指标，也不等价于产品级实时性能保证。

本节分段计时的适用范围需要明确。第一，50 张图像 batch 复查用于解释运行时口径，不直接替代 720 张完整验证集的检测指标。第二，代表性视频片段缺少逐帧人工标注，因此只用于说明连续处理路径和运行时耗时，不用于计算视频级 precision、recall 或 mAP。第三，`model_execute_ms` 是当前模型、二进制、阈值和板端环境下的工程观测值，不应扩展为所有输入条件下的固定产品服务指标。

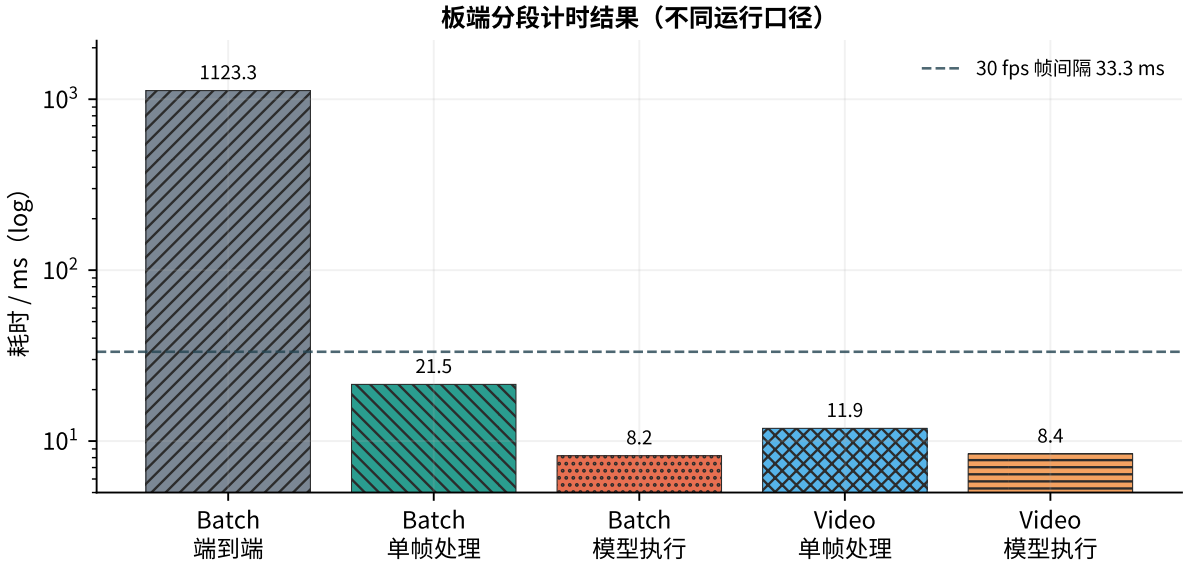

图 5-3 板端分段计时结果对比（对数坐标）

5.9 部署一致性综合分析

从完整验证集结果看，板端模型能够成功处理全部 720 张图像，并给出与双目标任务一致的分类别输出。该结果支持输入契约、类别契约、输出契约和运行契约在当前板端验证范围内未出现明显失配。特别是 *person* 与 *ebike* 两类均能形成可解释的 TP、FP、FN 统计，表明板端后处理没有出现类别顺序错位或输出张量无法解释的问题。

从阈值敏感性结果看，电动车召回率在 0.20–0.35 阈值区间内变化较小，说明电动车检测结果在当前验证集上具有一定阈值稳定性。相比之下，行人召回率下降更明显，说明近景遮挡和多人重叠场景仍可能产生低置信度候选框。该差异与第四章的场景风险分类一致，也说明场景风险分类可以用于解释部署后的指标变化。

从分段计时结果看，batch 图像验证链路端到端耗时与模型执行阶段耗时必须分开解释。完整验证集中的 1119.510 ms 表明 batch 验证链路可以完整复查，但不代表 OM 模型执行阶段本身需要约 1.1 s。新增分段计时补上了这一解释缺口，使本文能够同时报告可复查的 batch 验证结果和更细粒度的板端运行时拆解。

需要说明的是，本文尚未完成 PyTorch、ONNX、OM 和板端四阶段的逐样本统一匹配。因此，本节关于部署一致性的结论主要建立在完整板端验证、分类别统计、阈值后验重算和分段计时之上。跨阶段逐样本边框漂移仍作为后续工作保留。

5.10 场景风险与误差解释

结合第四章的场景风险分类，可以进一步解释实验结果中的分类别差异。行人类别的误差主要来自近景截断、多人重叠和门口区域干扰。当人体靠近摄像头或只出现局部

身体结构时，边框可能与真实框重合不足；当多人重叠时，NMS 可能抑制部分候选框，造成漏检或定位偏差。电动车类别虽然整体召回率较高，但局部可见样本仍然是主要风险来源，尤其是只出现车把、车轮或车身边缘时，置信度更容易接近阈值边界。

阈值敏感性结果也支持这一解释。电动车召回率在 0.20–0.35 阈值区间内变化较小，说明大部分电动车候选框分数较稳定；行人召回率随阈值升高持续下降，说明行人类别存在更多低置信度但可能正确的候选框。由此可见，阈值选择不能只依据总体 F1，还需要考虑不同类别在安全任务中的风险权重。

从部署一致性角度看，场景风险分类的价值在于帮助判断误差是否来自模型能力不足，还是来自迁移和后处理过程。如果某类风险样本在所有阶段都表现困难，问题更可能来自数据和模型表达；如果同一风险样本在训练端正确而板端异常，则需要优先检查输入契约、输出契约或后处理契约。本文尚未完成完整跨阶段逐样本匹配，但已经通过板端完整验证、阈值重算和分段计时建立了后续分析的基础。

5.11 结果讨论与局限

综合上述结果，本文方法的有效性体现在三个方面。第一，板端完整验证集结果表明 YOLO 双目标检测模型能够完成从训练权重到边缘设备执行的兼容迁移。第二，分类别结果说明模型对电动车目标具有较高召回率，符合电动车入梯风险识别的核心需求。第三，阈值敏感性重算和分段计时结果说明，本文不仅关注检测指标，也关注安全阈值和运行时口径是否可复查。

同时，实验也暴露出两个不足。第一，batch 图像验证链路端到端耗时仍然较高，说明当前图像验证路径更适合作为可复查实验链路，而不是最终实时产品形态的性能代表。第二，跨阶段逐样本一致性尚未形成完整数值表，无法定量报告每个目标从训练端到板端的边框漂移。因此，本文结论定位为“部署一致性评价方法与板端证据链”，而不是完整的高实时性产品系统。

5.12 本章小结

本章报告了 YOLO 双目标检测模型在边缘设备端的完整验证结果、分类别结果、阈值敏感性后验重算结果和分段计时结果。实验表明，模型在 720 张验证图像上取得 0.910 的 mAP@0.5，电动车类别 mAP@0.5 为 0.952，并在多个置信度阈值下保持较稳定的电动车召回率。新增分段计时进一步说明，batch 图像验证链路端到端耗时与模型执行阶段耗时必须分开解释。上述结果支撑了本文关于兼容迁移和部署一致性评价的主要结论。

结论与展望

本文面向电梯轿厢场景中的电动车入梯风险，研究了基于 YOLO 的行人与电动车双目标检测模型及其在海思/昇腾类边缘开发板上的兼容迁移问题。与只关注离线检测精度的研究不同，本文将训练权重、ONNX 中间表示、OM 离线模型、板端推理和后处理输出纳入同一评价框架，重点分析模型迁移后类别语义、边框解释、阈值行为和运行状态是否具备可复查的一致性。

本文的主要工作可以概括为三点。第一，面向电梯轿厢建立了 *person* + *ebike* 双目标检测任务，并结合门口结构、局部可见、拥挤重叠和光照变化等场景因素解释检测误差来源。第二，提出了自训练 YOLO 模型到海思/昇腾类边缘开发板的兼容迁移方法，围绕输入预处理、类别顺序、输出张量、后处理参数和运行状态建立接口契约。第三，构建了面向安全视觉的部署一致性评价思路，通过板端完整验证集结果、分类别指标、阈值敏感性后验重算、NMS/后处理消融协议、分段计时和代表性视频统计分析迁移后的实际行为。

实验结果表明，在 720 张图像验证集上，边缘设备端总体 precision 为 0.901，recall 为 0.923，F1 为 0.912，mAP@0.5 为 0.910，板端 batch 图像验证链路端到端平均单图处理耗时约为 1119.510 ms。其中，行人类别 mAP@0.5 为 0.869，电动车类别 mAP@0.5 为 0.952。阈值敏感性后验重算进一步显示，在 0.20–0.40 置信度阈值范围内，总体 F1 保持在 0.915–0.922 区间，电动车召回率保持在 0.953 以上。分段计时结果表明，50 张图像 batch 复查中的模型执行阶段均值约为 8.208 ms，代表性视频片段中的模型执行阶段均值约为 8.407 ms，说明 batch 端到端验证耗时不能等同于 OM/NPU 模型执行阶段耗时。上述结果说明，本文方法在当前验证集与代表性片段范围内表现出较稳定的双目标检测能力，并形成可复查的部署一致性评价证据。

本文的应用价值在于为电梯边缘安全视觉提供了一条可复查的落地路径。电梯轿厢场景的目标类别并不复杂，但系统必须在边缘设备上稳定运行，并且能够说明输出结果来自哪一组模型、阈值和后处理规则。本文将 YOLO 检测模型与海思/昇腾类开发板部署链路连接起来，使检测精度、阈值行为和运行状态能够在同一协议下被分析。这种思路也可为门厅、楼道、地下车库等封闭式公共空间的边缘视觉任务提供参考。

本文仍存在不足。首先，当前实证结果主要集中在板端完整验证、阈值后验重算和小样本分段计时，训练端、ONNX 端、OM 端和板端之间的逐样本统一匹配仍需进一步完善。其次，batch 图像验证链路端到端耗时仍然较高，完整 720 张验证集尚未使用新增计时埋点重跑分段统计，因此当前分段计时主要用于解释运行时口径，而不是替代完

整验证集结果。最后，本文聚焦于行人与电动车双目标检测，尚未将人数统计、跌倒检测或其他异常行为识别纳入主体实验。后续研究可以在保持接口契约和一致性评价框架的基础上，继续扩展跨阶段样本级对齐实验、完整验证集分段计时、轻量化推理优化和更多电梯安全视觉任务。

参考文献

[1] SHI W, CAO J, ZHANG Q, et al. Edge computing: vision and challenges[J/OL]. IEEE Internet of Things Journal, 2016, 3(5): 637-646. DOI: 10.1109/JIOT.2016.2579198.

[2] JACOB B, KLIGYS S, CHEN B, et al. Quantization and training of neural networks for efficient integer-arithmetic-only inference[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2018: 2704-2713. DOI: 10.1109/CVPR.2018.00286.

[3] HAN S, MAO H, DALLY W J. Deep compression: compressing deep neural networks with pruning, trained quantization and huffman coding[C]//International Conference on Learning Representations. 2016.

[4] HINTON G, VINYALS O, DEAN J. Distilling the knowledge in a neural network[A/OL]. arXiv (2015). https://arxiv.org/abs/1503.02531.

[5] STÄCKER L, FEI J, HEIDENREICH P, et al. Deployment of deep neural networks for object detection on edge AI devices with runtime optimization[A/OL]. arXiv (2021). https://arxiv.org/abs/2108.08166.

[6] CHEN P, LIU J, ZHUANG B, et al. AQD: towards accurate quantized object detection[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 104-113. DOI: 10.1109/CVPR46437.2021.00017.

[7] REDMON J, FARHADI A. YOLO9000: better, faster, stronger[C/OL]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 6517-6525. DOI: 10.1109/CVPR.2017.690.

[8] TAN M, PANG R, LE Q V. EfficientDet: scalable and efficient object detection[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 10778-10787. DOI: 10.1109/CVPR42600.2020.01079.

[9] HOWARD A, SANDLER M, CHU G, et al. Searching for MobileNetV3[C/OL]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 1314-1324. DOI: 10.1109/ICCV.2019.00140.

[10] TAN M, LE Q V. EfficientNet: rethinking model scaling for convolutional neural networks [C]//Proceedings of the 36th International Conference on Machine Learning. 2019: 6105-6114.

[11] LIU S, ZHA J, SUN J, et al. EdgeYOLO: an edge-real-time object detector[A/OL]. arXiv (2023). https://arxiv.org/abs/2302.07483.

[12] SHRIVASTAVA A, GUPTA A, GIRSHICK R. Training region-based object detectors with online hard example mining[C/OL]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 761-769. DOI: 10.1109/CVPR.2016.89.

[13] CHEN Y, LI Y, KONG T, et al. Scale-aware automatic augmentation for object detection [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 9563-9572.

[14] SHEN T C, CHU E T H. Edge-computing-based people-counting system for elevators using MobileNet–single-stage object detection[J/OL]. Future Internet, 2023, 15(10): 337. DOI: 10.3390/fi15100337.

[15] GIRSHICK R, DONAHUE J, DARRELL T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C/OL]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2014: 580-587. DOI: 10.1109/CVPR.2014.81.

[16] GIRSHICK R. Fast R-CNN[C/OL]//Proceedings of the IEEE International Conference on Computer Vision. 2015: 1440-1448. DOI: 10.1109/ICCV.2015.169.

[17] REN S, HE K, GIRSHICK R, et al. Faster R-CNN: towards real-time object detection with region proposal networks[J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(6): 1137-1149. DOI: 10.1109/TPAMI.2016.2577031.

[18] LIU W, ANGUELOV D, ERHAN D, et al. SSD: single shot MultiBox detector[C/OL]// European Conference on Computer Vision. 2016: 21-37. DOI: 10.1007/978-3-319-46448-0_2.

[19] REDMON J, DIVVALA S, GIRSHICK R, et al. You only look once: unified, real-time object detection[C/OL]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 779-788. DOI: 10.1109/CVPR.2016.91.

[20] LIN T Y, DOLLÁR P, GIRSHICK R, et al. Feature pyramid networks for object detection [C/OL]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 2117-2125. DOI: 10.1109/CVPR.2017.106.

[21] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection[C/OL]// Proceedings of the IEEE International Conference on Computer Vision. 2017: 2999-3007. DOI: 10.1109/ICCV.2017.324.

[22] HE K, GKIOXARI G, DOLLÁR P, et al. Mask R-CNN[C/OL]//Proceedings of the IEEE International Conference on Computer Vision. 2017: 2961-2969. DOI: 10.1109/ICCV.2017.322.

[23] ZHOU X, WANG D, KRÄHENBÜHL P. Objects as points[A/OL]. arXiv (2019). https://arxiv.org/abs/1904.07850.

[24] REDMON J, FARHADI A. YOLOv3: an incremental improvement[A/OL]. arXiv (2018). https://arxiv.org/abs/1804.02767.

[25] BOCHKOVSKIY A, WANG C Y, LIAO H Y M. YOLOv4: optimal speed and accuracy of object detection[A/OL]. arXiv (2020). https://arxiv.org/abs/2004.10934.

[26] GE Z, LIU S, WANG F, et al. YOLOX: exceeding YOLO series in 2021[A/OL]. arXiv (2021). https://arxiv.org/abs/2107.08430.

[27] WANG C Y, BOCHKOVSKIY A, LIAO H Y M. YOLOv7: trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[A/OL]. arXiv (2022). https://arxiv.org/abs/2207.02696.

[28] LI C, LI L, JIANG H, et al. YOLOv6: a single-stage object detection framework for industrial applications[A/OL]. arXiv (2022). https://arxiv.org/abs/2209.02976.

[29] CARION N, MASSA F, SYNNAEVE G, et al. End-to-end object detection with transformers[C/OL]//European Conference on Computer Vision. 2020: 213-229. DOI: 10.1007/978-3-030-58452-8_13.

[30] REZATOFIGHI H, TSOI N, GWAK J, et al. Generalized intersection over union: a metric and a loss for bounding box regression[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 658-666. DOI: 10.1109/CVPR.2019.00075.

[31] ZHENG Z, WANG P, LIU W, et al. Distance-IoU loss: faster and better learning for bounding box regression[J/OL]. Proceedings of the AAAI Conference on Artificial Intelligence, 2020, 34(07): 12993-13000. DOI: 10.1609/AAAI.V34I07.6999.

[32] SZEGEDY C, LIU W, JIA Y, et al. Going deeper with convolutions[C/OL]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2015: 1-9. DOI: 10.1109/CVPR.2015.7298594.

[33] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C/OL]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 770-778. DOI: 10.1109/CVPR.2016.90.

[34] HOWARD A G, ZHU M, CHEN B, et al. MobileNets: efficient convolutional neural networks for mobile vision applications[A/OL]. arXiv (2017). https://arxiv.org/abs/1704.04861.

[35] SANDLER M, HOWARD A, ZHU M, et al. MobileNetV2: inverted residuals and linear bottlenecks[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2018: 4510-4520. DOI: 10.1109/CVPR.2018.00474.

[36] IANDOLA F N, HAN S, MOSKEWICZ M W, et al. SqueezeNet: AlexNet-level accuracy with 50x fewer parameters and <0.5MB model size[A/OL]. arXiv (2016). https://arxiv.org/abs/1602.07360.

[37] MA N, ZHANG X, ZHENG H T, et al. ShuffleNet V2: practical guidelines for efficient CNN architecture design[C/OL]//European Conference on Computer Vision. 2018: 122-138. DOI: 10.1007/978-3-030-01264-9_8.

[38] TAN M, CHEN B, PANG R, et al. MnasNet: platform-aware neural architecture search for mobile[A/OL]. arXiv (2018). https://arxiv.org/abs/1807.11626.

[39] CAI H, GAN C, WANG T, et al. Once-for-all: train one network and specialize it for efficient deployment[A/OL]. arXiv (2019). https://arxiv.org/abs/1908.09791.

[40] JOUPPI N P, YOUNG C, PATIL N, et al. In-datacenter performance analysis of a tensor processing unit[C/OL]//Proceedings of the 44th Annual International Symposium on Computer Architecture. 2017: 1-12. DOI: 10.1145/3079856.3080246.

[41] CHEN T, MOREAU T, JIANG Z, et al. TVM: an automated end-to-end optimizing compiler for deep learning[A/OL]. arXiv (2018). https://arxiv.org/abs/1802.04799.

[42] DONG Z, YAO Z, GHOLAMI A, et al. HAWQ: hessian aware quantization of neural networks with mixed-precision[C/OL]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 293-302. DOI: 10.1109/ICCV.2019.00038.

[43] KRISHNAMOORTHI R. Quantizing deep convolutional networks for efficient inference: a whitepaper[A/OL]. arXiv (2018). https://arxiv.org/abs/1806.08342.

[44] GHOLAMI A, KIM S, DONG Z, et al. A survey of quantization methods for efficient neural network inference[A/OL]. arXiv (2021). https://arxiv.org/abs/2103.13630.

[45] BODLA N, SINGH B, CHELLAPPA R, et al. Soft-NMS: improving object detection with one line of code[C/OL]//Proceedings of the IEEE International Conference on Computer Vision. 2017: 5561-5569. DOI: 10.1109/ICCV.2017.593.

[46] WOJKE N, BEWLEY A, PAULUS D. Simple online and realtime tracking with a deep association metric[C/OL]//Proceedings of the IEEE International Conference on Image Processing. 2017: 3645-3649. DOI: 10.1109/ICIP.2017.8296962.

[47] ZHANG Y, SUN P, JIANG Y, et al. ByteTrack: multi-object tracking by associating every detection box[C/OL]//European Conference on Computer Vision. 2022: 1-21. DOI: 10.1007/978-3-031-20047-2_1.

[48] CAO Z, SIMON T, WEI S E, et al. Realtime multi-person 2D pose estimation using part affinity fields[C/OL]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 1302-1310. DOI: 10.1109/CVPR.2017.143.

[49] FEICHTENHOFER C, FAN H, MALIK J, et al. SlowFast networks for video recognition[C/OL]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 6201-6210. DOI: 10.1109/ICCV.2019.00630.

[50] BEWLEY A, GE Z, OTT L, et al. Simple online and realtime tracking[C/OL]//Proceedings of the IEEE International Conference on Image Processing. 2016: 3464-3468. DOI: 10.1109/ICIP.2016.7533003.

致谢

本科毕业设计从开题、系统实现、设备验证到论文写作的每一步，都离不开老师和同学们的帮助。在此，谨向在本课题推进过程中给予指导、支持和鼓励的师长、同学与家人表示诚挚感谢。

首先，衷心感谢指导老师钟竞辉老师在课题选题、研究收敛与论文组织方面给予的持续指导。老师在研究问题凝练、技术路线选择以及学术表达规范等方面给予的指导，使我能够将原本偏工程化的项目逐步整理为具备论文叙事结构的研究工作。

其次，感谢项目实践过程中提供帮助的同学与协作者。围绕电梯边缘视觉系统的训练、导出、量化和设备端运行，需要跨越服务器与边缘设备等多个环境，相关经验的积累与问题排查离不开大家的交流与支持。

同时，感谢家人在学习与毕业设计期间给予的理解、陪伴与鼓励。正是因为有稳定的支持，我才能持续投入到模型实验、系统验证与论文写作的各项工作中。

最后，感谢本科阶段所有授课老师和实验课程所提供的知识积累。深度学习、计算机视觉、嵌入式系统与软件工程等课程的训练，为本课题的完成打下了坚实基础。

附录 A 补充复查表格

本附录给出实验复查时可使用的记录字段。附录表格不替代正文实验结果，而是用于说明困难样本和部署一致性复查应保留哪些信息。

A.1 困难样本复查字段

表 A-1 用于记录困难样本的观察结果。该表仅保留论文复查所需字段，不展开本地文件组织细节，也不把样本整理为新的人工分组实验。

表 A-1 困难样本复查字段

字段	记录内容	检测表现	备注
样本编号	图像或视频帧标识	是否有漏检、误检或重复框	对应日志或截图路径
场景描述	文字描述可见干扰	类别分数和边框变化	不作为统计分组
复查结论	关联阈值、NMS 或后处理设置	是否需要进入正文讨论	对应表格或图编号

A.2 部署一致性复查字段

表 A-2 给出了部署一致性复查时应记录的字段。后续若补充训练端、ONNX 端、OM 端和板端逐样本对齐实验，可沿用该表记录类别、边框、阈值和运行状态。

表 A-2 部署一致性复查字段

复查项	记录内容	判断依据
类别顺序	person / ebike 是否一致	类别配置与输出解释一致
输入预处理	尺寸、缩放、颜色通道	输入契约一致
输出张量	坐标格式、分数含义	输出契约一致
后处理参数	conf、NMS 阈值	阈值行为可比较
运行状态	成功样本数、失败样本数、平均时延	板端结果可复查